Universidade Federal de Uberlândia
Faculdade de Computação

Análise Léxica

Curso de Bacharelado em Ciência da Computação
GBC071 - Construção de Compiladores
Prof. Luiz Gustavo Almeida Martins

Etapa de Análise do Compilador

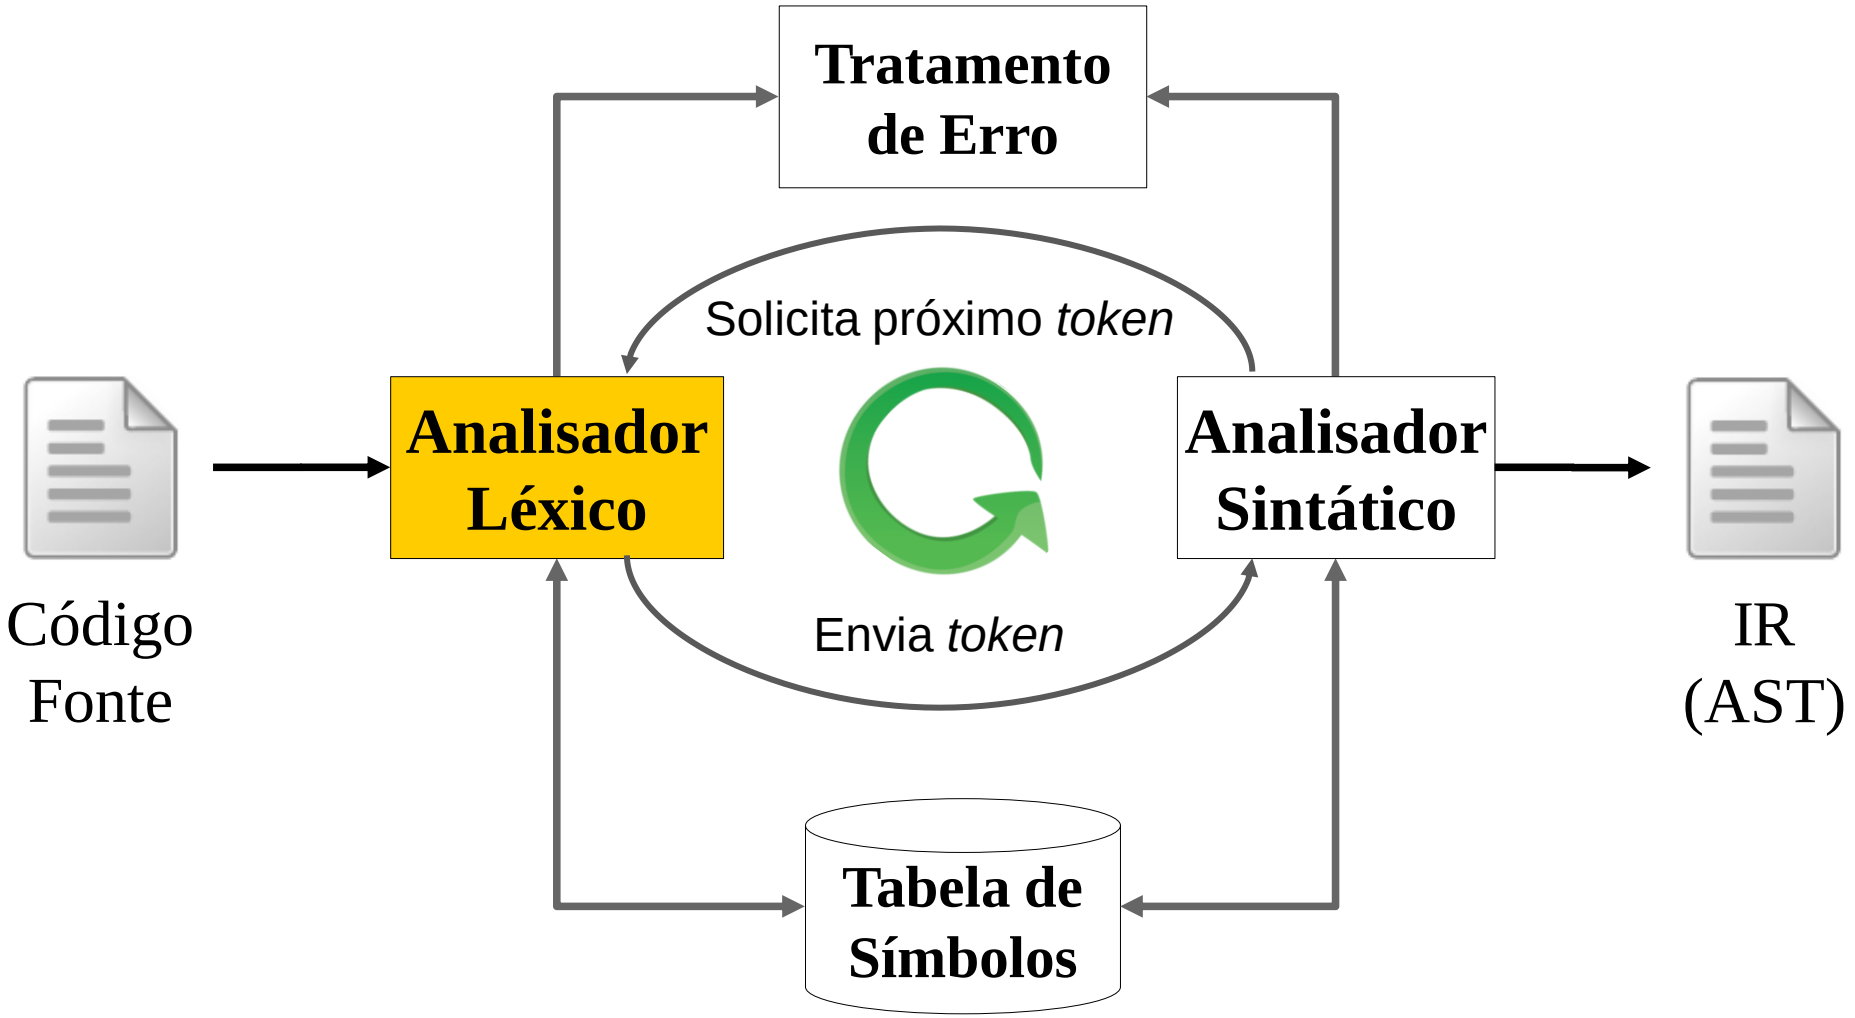

Processo iterativo e reativo

Projeto da Etapa de Análise

- Por que dividir análise léxica e sintática?
  - Permite simplificar uma das fases (**projeto mais simples**)
    - **Ex:** análise sintática com e sem tratamento para comentários
  - Permite a adoção de técnicas especializadas/otimizadas para certas tarefas (**melhor eficiência do compilador**)
    - **Ex:** técnicas de buferização especializadas para a leitura de caracteres e o processamento de *tokens*
  - Facilita a portabilidade do compilador (**manutenção**)
    - Peculiaridades da linguagem ou dos dispositivos podem ser restringidas ao analisador léxico **facilitando modificações**
    - **Ex:** Tratamento de símbolos especiais (^ em Pascal) ou fora do padrão (ex: letras do alfabeto grego)

Análise Léxica

- Análise léxica é a 1ª fase da etapa de análise
  - Envolve **varredura** (*scanner*) **e análise** propriamente dita (*lexer*)
  - Implementada como uma **sub-rotina do analisador sintático**

- **Tarefa principal: agrupar os caracteres** do código fonte em ***tokens***
  - **Ler os caracteres de um *buffer* de entrada** do programa fonte
  - **Agrupá-los em lexemas**
  - **Produzir uma sequência de *tokens*** como saída
    - Usada pelo analisador sintático para validar as regras da gramática

- Pode realizar outras **tarefas secundárias**:
  - Remover símbolos desnecessários
    - Comentários e separadores (espaço em branco, tabulação e quebra de linha)
  - Correlacionar as mensagens de erro com o código fonte
  - Processar diretivas de controle (**ex:** expansão de macros)

Token

- **Classe de elementos aceitos** em uma linguagem de programação
  - **Unidade básica da sintaxe**
  - **Ex:** identificadores, operadores, palavras-chave, etc.

- **Elo de ligação** entre as análises léxica e sintática
  - Representa os **lexemas do código fonte**
    - **Palavras aceitas** pela **linguagem**
  - Corresponde a um **nó folha da árvore sintática**
    - **Símbolo terminal** de uma **gramática livre de contexto**

Token

- Representado por um par ***<Nome, Atributo>***:
  - **Nome:** símbolo abstrato que indica o tipo do *token*
    - Símbolos de entrada do analisador sintático
  - **Atributo:** guarda informações adicionais necessárias (**opcional**)
    - Atributo pode ser um **tipo estruturado** que guarda várias informações
    - **Ex:** lexema encontrado, valor de dado, localização na entrada, etc.
- **Classes de *tokens*** presentes em uma linguagem:
  - **Palavras-chave**
  - **Operadores** (organizados individualmente ou em classes)
  - **Identificadores** (ID)
  - **Constantes** (**ex:** número ou cadeia de literais)
  - **Símbolos de pontuação** (**ex:** parênteses, ponto-e-vírgula, etc.)

Exercício

- Identifique os ***tokens*** dos códigos abaixo, associando a cada um seu par **<Nome,Atributo>**

Pascal

```
function max (i, j: integer): integer;
{ return maximum of integers I and j}
begin
  if i > j then max := i
  else max := j
end;
```

C

```
int max (i , j) int i, j;
{ /* maximum of integers i and  j */
return i > j ? i : j;
}
```

- fonte: [Aluisio, 2011]

Padrão de um *Token*

- **Regra** que define o **conjunto de palavras** associado a um *token*
  - **Descreve a forma (cadeia de caracteres)** que os lexemas de um *token* podem assumir
  - **Ex:** Qualquer ID é formado por uma letra seguida por letras, números e “_”

- **Expressões regulares** são uma importante notação para **especificar os padrões de lexemas**
  - **Ex:** *letra* (*letra* + *digito* + _)*

- Os padrões são usados na **construção dos reconhecedores** das cadeias do conjunto

Lexema

- **Sequência de caracteres** no programa fonte **que casa com o padrão** de um *token*

- **Palavra reconhecida** pelo analisador léxico como uma instância do *token*

- **Exemplos:** (fonte: [Aho, 2008])

Token	**Descrição Informal**	**Exemplo Lexemas**
ID	Letra seguida por letras e dígitos	Nome, D2, vlr_max
Literal	Qualquer caractere (≠ de “) entre “s	“exemplo de token”
Número	Qualquer constante numérica	3.14159, -3, 0.32e6
Comparação	< ou > ou <= ou >= ou == ou !=	<, ==
while	while	while

Atributos dos *Tokens*

- Usado quando **mais de um lexema cada com o padrão** do *token*
  - **Ex:** identificador, operador, etc.

- Fornece **informações adicionais** para as fases seguintes do compilador
  - **Descreve o lexema** representado pelo *token*
  - **Nome do *token*** influencia nas decisões durante a **análise sintática**
  - **Valor do atributo** influencia na tradução do token **após o reconhecimento sintático**

Erros Léxicos

- Identificar um erro no código fonte durante a análise léxica é difícil sem o auxílio de outros componentes
  - **Ex:** *fi* é um identificador ou o *if* escrito errado?

- **Erros léxicos** ocorrem quando **nenhum dos padrões para *tokens* casa** com nenhum prefixo da entrada restante
  - **Ex:** símbolo desconhecido, lexemas mal formados, identificadores muito grandes e fim de arquivo inesperado

- Erros associados ao **tratamento de constantes:**
  - Exceder o limite de casas decimais e do expoente de números reais (**tanto no tamanho quanto no valor**)
  - Exceder o limite máximo da cadeia de caracteres
  - Exceder o limite do número de dígitos e do valor de um inteiro

Erros Léxicos

- **Estratégias de recuperação** podem ser usadas
  - Envolve transformações na entrada restante:
    - **Remover** um caractere
    - **Inserir** um caractere que falta
    - **Substituir** um caractere por outro
    - **Transpor** dois caracteres adjacentes
  - "**Modo pânico**": remove caracteres até reconhecer o lexema
  - **Estratégia mais simples** aplica uma **única transformação**
  - **Estratégia mais geral** busca encontrar o **menor número de transformações** necessárias para obter um lexema válido
    - Na prática, é uma **estratégia muito dispendiosa**
    - Não garante efetividade dos resultados

Buffering da Entrada

- **Identificação correta de um lexema** pode exigir a leitura de **1 ou + caracteres a frente** (***lookahead***)
  - **Ex:** na linguagem Fortran, as palavras-chave não são reservadas e os espaços são desconsiderados
    - DO 5 I = 1**.**25 ⇒ lexema: **DO5I** *Token*: **ID**
    - DO 5 I = 1**,**25 ⇒ lexema: **DO** *Token*: **DO**

- **Técnicas especializadas de *buffering*** são empregadas para reduzir o custo da operação
  - **Exemplo:**
    - ***2 buffers*** para tratar *lookaheads* grandes com segurança
    - Uso de "**sentinelas**" para evitar verificação de fim do *buffer*

Pares de *Buffer*

- Adota 2 *buffers* de entrada de mesmo tamanho
  - Relacionado com o **tamanho do bloco do disco** (**ex:** 4096 bytes)

- Comando de leitura do sistema **carrega todo o *buffer*** ao invés de um único caractere
  - *Buffers* são recarregados alternadamente
  - Caractere especial **EOF** define fim do arquivo

- Abordagem adota **2 ponteiros**:
  - ***ini*:** marca o início do lexema atual
  - ***prox*:** indica o próximo caractere a ser lido
    - Implementa o *lookahead* até que haja um casamento de padrão
    - Provoca a operação de recarga sempre que extrapola o tamanho do *buffer*

Pares de *Buffer*

- **Exemplo:** (retirado de [Aho, 2008])

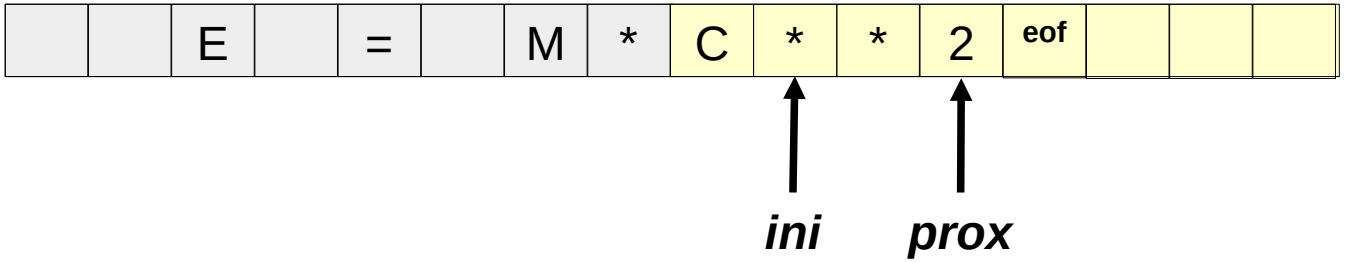

Pares de *Buffer*

- **Exemplo:** (retirado de [Aho, 2008])

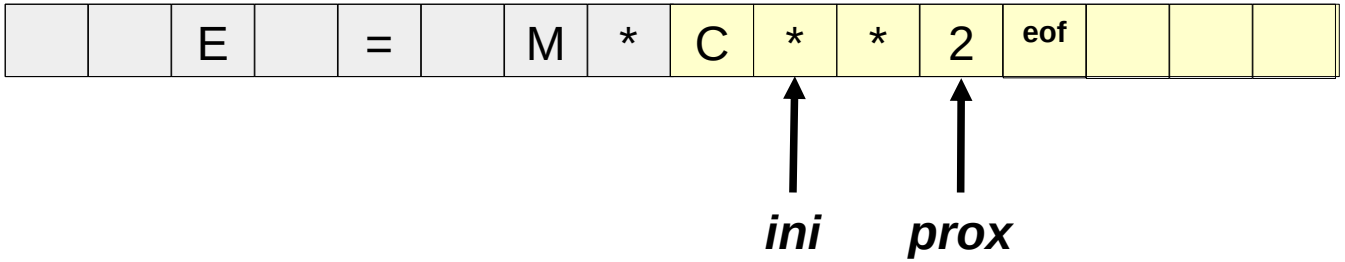

- Podemos esgotar o espaço em *buffer*?
  - **Lexemas são geralmente pequenos**
    - 1 ou 2 caracteres de *lookahead* são suficientes
  - Problema na **leitura de cadeias longas** (> *buffer*)
    - Linguagens que não tratam palavras-chave como reservadas
    - Existência de lexemas maiores que o *buffer* (ex: literais)

Sentinelas

- Envolve incluir um **caractere extra** (**sentinela**) no fim de cada *buffer*
  - Geralmente é usado o caractere especial **EOF**
  - Exige **uma posição a mais na estrutura** de armazenamento
- Visa reduzir a quantidade de testes a cada caractere lido
  - **Original:** fim de *buffer* e qual caractere lido
  - **Sentinela:** qual caractere lido
- Posição do **EOF** indica o cenário a ser tratado:
  - **Final do *buffer*: EOF** na última posição
  - **Final do arquivo de entrada: EOF** nas demais posições

Sentinelas

- **Exemplo:** (retirado de [Aho, 2008])

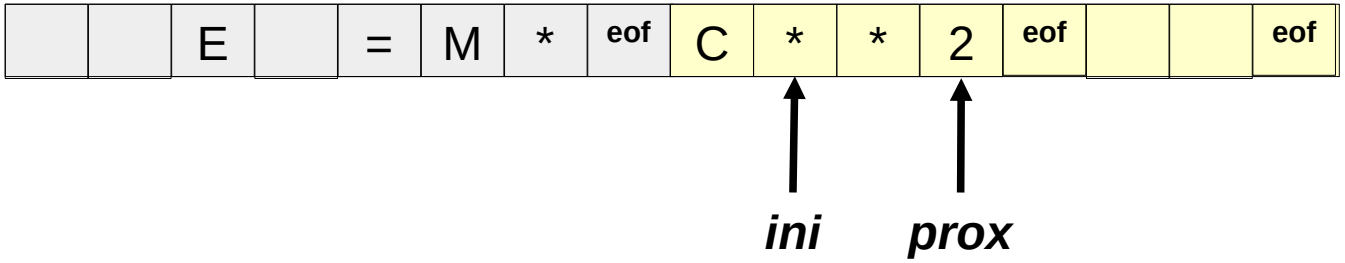

Sentinelas

- **Exemplo:** (retirado de [Aho, 2008])

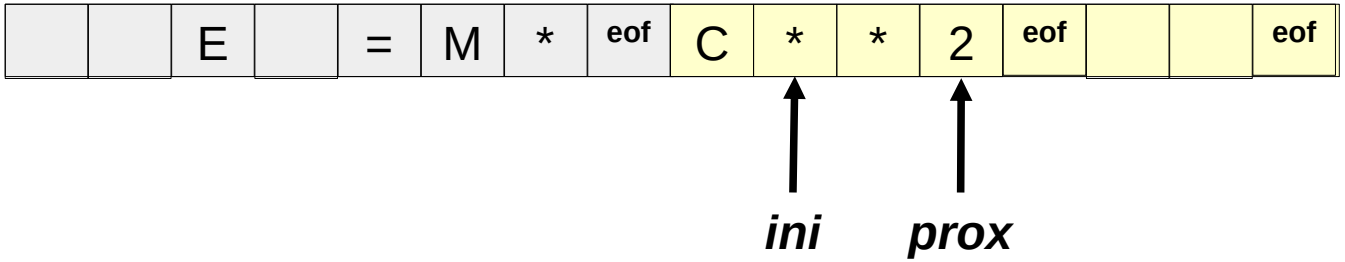

- **Tratamento do EOF:**
  - SE *prox* está no fim do 1º *buffer* ENTÃO
    - carrega o 2º *buffer*
    - *prox* = início do 2º *buffer*
  - SENÃO SE *prox* está no fim do 2º buffer ENTÃO
    - carrega o 1º *buffer*
    - *prox* = início do 1º *buffer*
  - SENÃO // Fim do arquivo
    - fim da análise léxica

Expressões Regulares

- **Notação formal** usada para **especificar a estrutura (padrões)** dos *tokens*
  - Possibilita um analisador léxico sem erros **(estrutura precisa)**
  - **Ex:** *string* definida como uma cadeia de **caracteres** entre aspas
    - Não são todos os caracteres que são permitidos (ex: <CR><LF>)
  - **Ex:** números reais em notação de ponto fixo (ex: 3.0 e 0.12)
    - **3.** e **.12** são aceitos em Fortran, mas não em Pascal

- Descreve as linguagens a partir de **3 operações** sobre os símbolos de algum alfabeto:
  - **União:** $L \cup M = \{s \mid s \in L \text{ ou } s \in M\}$
  - **Concatenação:** $LM = \{st \mid s \in L \text{ ou } t \in M\}$
  - **Fecho *Kleene*:** $L^* = \cup^{i=0..\infty} L$

Processo recursivo

- Expressões regulares podem ser **definidas recursivamente a partir de expressões menores**
  - Cada expressão *r* denota uma linguagem *L(r)*

- Regras que formam a **base** das expressões regulares:
  - ε é uma expressão regular e *L*(ε) é {ε}
  - Se *a* é um símbolo de Σ, então **a** é uma expressão regular e *L*(**a**) = {*a*}

- Regras que formam a parte indutiva das expressões regulares:
  - (*r*)|(*s*) é uma expressão regular denotando $L(r) \cup L(s)$
  - *(r)(s) é uma expressão regular denotando L(r)L(s)*
  - *(r)* é uma expressão regular denotando L(r)**
  - Se *r* é uma expressão regular, **(***r***)** também é e denota a mesma linguagem

Precedência dos Operadores

- **Precedência:**
  - Fecho (*)
  - Concatenação
  - União (|)

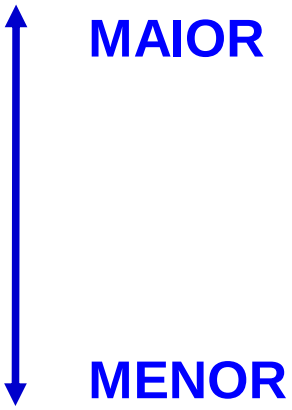

- Todos com **associatividade à esquerda**

Definições Regulares

- Especifica expressões regulares a partir de outras expressões previamente definidas
  - **Expressões mais simples** são nomeadas e seus nomes usados em **expressões mais complexas**

- **Não são usadas definições recursivas**
  - Nova definição baseia-se nas anteriores

- Permite gerar expressões regulares **apenas com os símbolos do Σ**
  - Aplicação de **substituições consecutivas** das definições mais simples nas mais complexas

Definições Regulares

- **Seja Σ o alfabeto. Uma definição regular é uma sequência de definições da forma:**
  - $d_1 \rightarrow r_1$
  - $d_2 \rightarrow r_2$
  - …
  - $d_n \rightarrow r_n$

  – Cada $\boldsymbol{d_i}$ é um **novo símbolo** $\notin \Sigma \cup \{d_1, d_2, \ldots, d_{n-1}\}$
  – Cada $\boldsymbol{r_i}$ é uma **expressão regular** formada por símbolos $\in \Sigma \cup \{d_1, d_2, \ldots, d_{n-1}\}$

Definições Regulares

- **Exemplos:** (retirado de [Aho, 2008])
  - **Identificadores em C:**
    - *letra_* → A | B | … | Z | a | b | … | z | _
    - *digito* → 0 | 1 | … | 9
    - *id* → *letra_* (*letra_* | *digito*)*
  - **Números sem sinal (inteiro ou ponto flutuante):**
    - *digito* → 0 | 1 | … | 9
    - *digitos* → *digito digito**
    - *fração* → .*digitos* | ε
    - *exponente* → (E(+ | - | ε) *digitos*) | ε
    - *numero* → *digitos fração expoente*

Definições Regulares

- **Exemplos:** (retirado de [Aho, 2008])
  - **Identificadores em C:**
    - *letra_* → A | B | … | Z | a | b | … | z | _
    - *digito* → 0 | 1 | … | 9
    - *id* → *letra_* (*letra_* | *digito*)*
  - **Números sem sinal (inteiro ou ponto flutuante):**
    - *digito* → 0 | 1 | … | 9
    - *digitos* → *digito digito**
    - *fração* → .*digitos* | ε
    - *exponente* → (E(+ | - | ε) *digitos*) | ε
    - *numero* → *digitos fração expoente*

ε implementa a opcionalidade

Como seria a derivação de 512, 0.365 e 6.32E-3?

Notação Estendida

- Extensões são adicionadas para **melhorar a capacidade de especificar** padrões de cadeia
  - Não fazem parte da notação convencional de expressões regulares
  - Usadas na **especificação de analisadores léxicos** (**ex:** Lex)

- **Extensões importantes:**
  - **Operador +:** representa o **fecho positivo** (uma ou mais instâncias)
    - (*r*) denota a linguagem *L*(r)
    - $r^* = r \mid \varepsilon$ e $r = rr^*$
  - **Operador ?:** representa **zero ou uma instância**
    - (*r*)? é equivalente a $r \mid \varepsilon$
  - **Operador [ ]:** representa classes de caracteres
    - [*abc*] é equivalente a $a \mid b \mid c$
    - Útil para representar **sequências lógicas**
      - [*a*-*z*] é equivalente a $a \mid b \mid \ldots \mid z$

Notação Estendida

- **Exemplo: identificadores**
  - (retirado de [Aho, 2008])

  - **Notação convencional:**
    - *letra_* → A | B | … | Z | a | b | … | z | _
    - *digito* → 0 | 1 | … | 9
    - *id* → *letra_* (*letra_* | *digito*)*

  - **Notação estendida:**
    - *letra_* → [A – Z a – z _]
    - *digito* → [0 – 9]
    - *id* → *letra_* [*letra_ digito*]*

Notação Estendida

- **Exemplo: números sem sinal**
  - (retirado de [Aho, 2008])

  - **Notação convencional:**
    - *digito* → 0 | 1 | … | 9
    - *digitos* → *digito digito**
    - *fração* → .*digitos* | ε
    - *exponente* → (E(+ | - | ε) *digitos*) | ε
    - *numero* → *digitos fração expoente*

  - **Notação estendida:**
    - *digito* → [0 - 9]
    - *digitos* → *digito*
    - *numero* → *digitos* (.*digitos*) ? (E[+ -] ? *digitos*) ?

Outras Extensões do *Lex*

EXPRESSÃO	CASA COM	EXEMPLO
c	o único caractere não operador *c*	`a`
\c	o caractere *C* literalmente	`\*`
"s"	a cadeia *s* literalmente	`"***"`
.	qualquer caractere menos quebra de linha	`a.*b`
^	o início de uma linha	`^abc`
$	o fim de uma linha	`abc$`
[s]	qualquer um dos caracteres na cadeia *s*	`[abc]`
[^s]	qualquer caractere não presente na cadeia *s*	`[^abc]`
r*	zero ou mais cadeias casando com *r*	`a*`
r+	uma ou mais cadeias casando com *r*	`a+`
r?	zero ou um *r*	`a?`
r{m,n}	entre *m* e *n* ocorrências de *r*	`a[1,5]`
r_1r_2	um r_1 seguido por um r_2	`ab`
$r_1 \mid r_2$	um r_1 ou um r_2	`a|b`
(r)	o mesmo que *r*	`(a|b)`
r_1/r_2	R_1 quando seguido por r_2	`abc/123`

- (retirado de [Aho, 2008])

Reconhecimento de *Tokens*

- Considere o fragmento de gramática:
  - *stmt* → **if** *expr* **then** *stmt* **else** *stmt* |
  - **if** *expr* **then** *stmt* | *ε*
  - *expr* → *term* **relop** *term* | *term*
  - *term* → **id** | **numero**

  - **Terminais** da gramática são **nomes dos *tokens***

  - *Tokens* devem ser reconhecidos:
    - **Palavras-chave** associadas a **if**, **then** e **else**
    - **Lexemas** que casam com os padrões de **relop**, **id** e **numero**

  - **Separadores** (***ws***) devem ser removidos **(tratamento especial)**
    - **Não retorna** *token* ao analisador sintático
    - Provoca a **reinicialização da análise léxica** a partir do caractere seguinte

Reconhecimento de *Tokens*

- Definições regulares dos padrões dos *tokens*:
  - *digito* → [0 - 9]
  - *digitos* → *digito*
  - *letra* → [A - Za - z]
  - ***numero*** → *digitos* (*.digitos*) ? *(*E[+ -] ? *digitos*) ?
  - ***id*** → *letra* (*letra* | *digito*)*
  - ***relop*** → < | > | <= | >= | = | <>
  - ***if*** → if
  - ***then*** → then
  - ***else*** → else
  - ***ws*** → (“ “ | \t | \n)

Reconhecimento de *Tokens*

Lexemas	Nome do *Token*	Valor do Atributo
Qualquer *ws*	**–**	**–**
if	**if**	**–**
then	**then**	**–**
else	**else**	**–**
Qualquer *id*	**id**	Posição na tabela de símbolos
Qualquer *numero*	**numero**	Posição na tabela de símbolos
<	**relop**	LT
<=	**relop**	LE
=	**relop**	EQ
<>	**relop**	NE
>	**relop**	GT
>=	**relop**	GE

- fonte: [Aho, 2008]

Reconhecimento de *Tokens*

Lexemas	Nome do *Token*	Valor do Atributo
Qualquer *ws*	**–**	**–**
if	**if**	**–**
then	**then**	**–**
else	**else**	**–**
Qualquer *id*	**id**	Posição na tabela de símbolos
Qualquer *numero*	**numero**	Posição na tabela de símbolos
<	**relop**	LT
<=	**relop**	LE
=	**relop**	EQ
<>	**relop**	NE
>	**relop**	GT
>=	**relop**	GE

O operador encontrado **influenciará o código que será gerado** pelo compilador

- fonte: [Aho, 2008]

Diagramas de Transição

- Fluxogramas usados no **reconhecimento** dos *tokens*
  - Muito parecido com os **autômatos finitos**
  - Gerados a partir dos **padrões** dos *tokens*
    - **Estados:** nós que representam as condições que podem ocorrer durante a procura de lexemas que casem com um padrão
      - Possui um **estado inicial** e um ou mais **estados finais ou de aceitação**
    - **Transições:** arestas direcionadas associadas à leitura de um ou + símbolos do alfabeto
      - Seu uso pode provocar **mudança de estado e avanço do *prox***
  - **Estados de aceitação** indicam um **lexema aceito**
    - Estão **associados às ações** que devem ser realizadas
    - **Símbolo *** indica **recuo do *prox* em uma posição**

Diagramas de Transição

- **Exemplo:** diagrama para o *token* **relop**

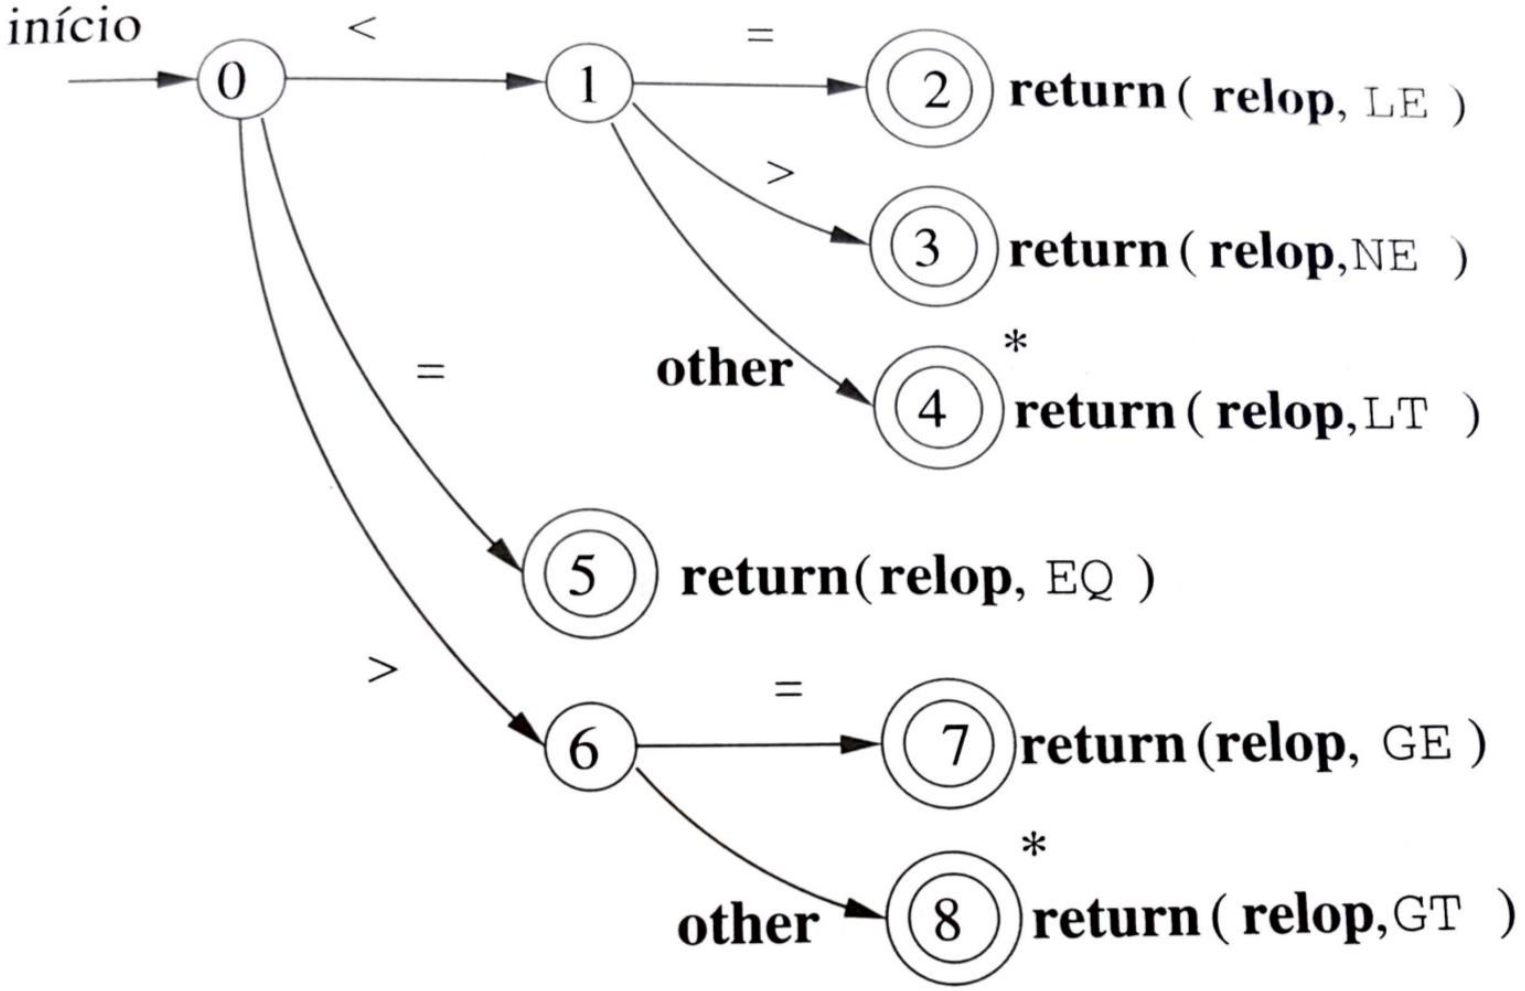

- fonte: [Aho, 2008]

Palavras-Chave vs. Identificadores

- Diferenciar **palavras-chave e identificadores** pode ser um problema
  - Palavras-chave casam com o padrão dos identificadores
  - Considerar as **palavras-chave como reservadas** ajuda no reconhecimento
    - **Palavras reservadas não podem ser identificadores**

- Existem 2 formas de lidar com palavras reservadas:
  - Tratar **palavras reservadas como identificador**
  - **Criar diagramas separados** para cada palavra-chave

Palavras-Chave vs. Identificadores

- **Tratar palavras reservadas como identificador:**
  - Inicia tabela de símbolos com as palavras reservadas
  - Consulta a tabela antes de incluir um novo lexema
    - Se encontrar registro, retorna o **nome do *token***
    - Senão inclui o novo lexema e retorna **ID**

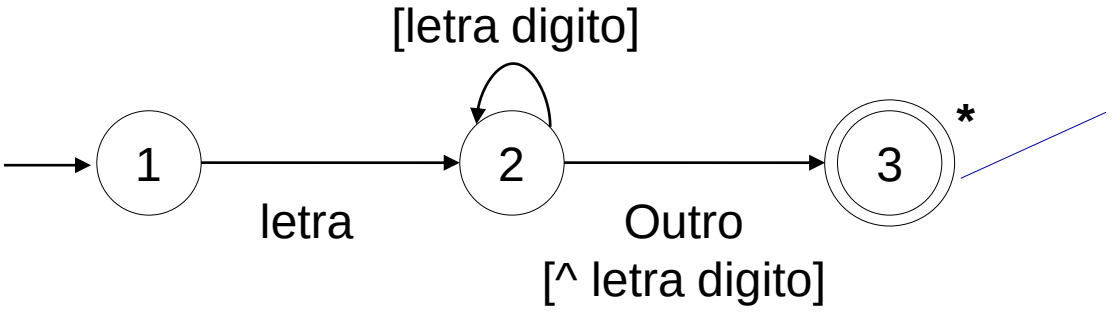


```
X = getToken();

if (X == NULL)
    return setID();
else
    return X;
```

Palavras-Chave vs. Identificadores

- **Criar diagramas separados** para cada palavra chave:
  - **Verifica se a cadeia terminou** antes de associar o lexema ao *token*
    - Para evitar erros **prioriza o maior prefixo aceito**
    - **Ex:** *ifan* é um identificador e não a palavra-chave *if*
  - **Se lexema casar com 2 padrões**, **deve priorizar a palavra chave**

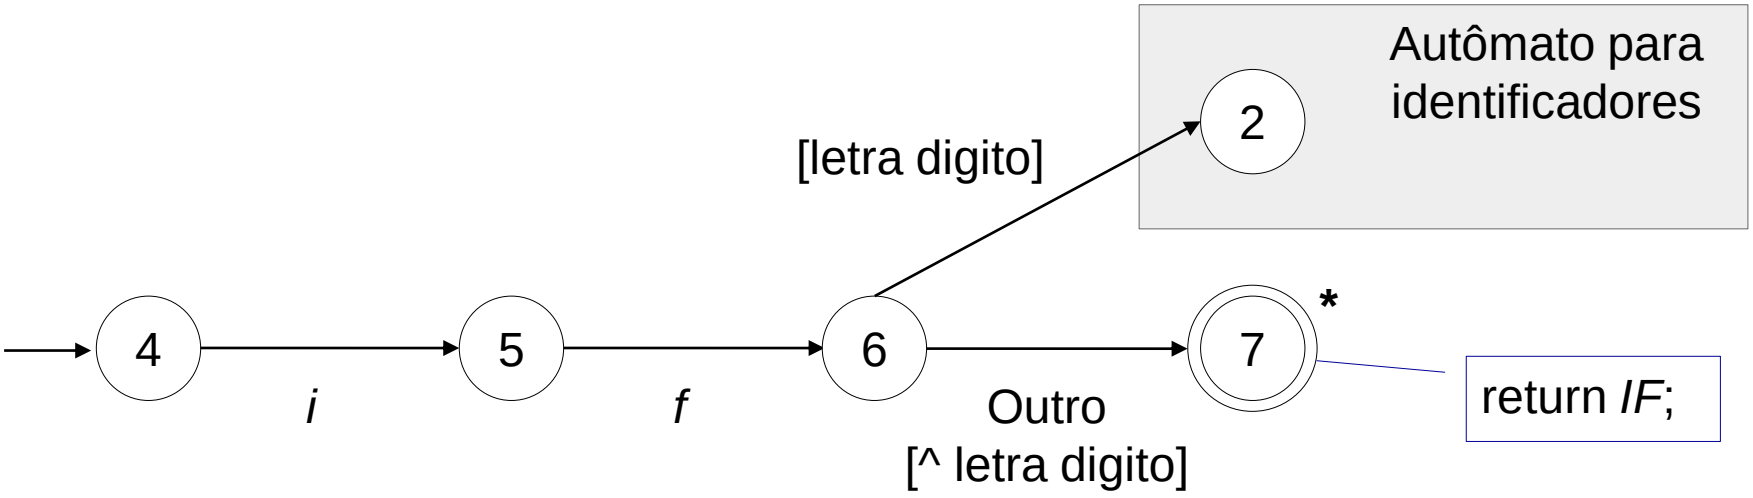

Diagramas de Transição

- Como seriam os diagramas de transição para os demais *tokens* do nosso estudo de caso?
  - **then**, **else**, **ws** e **número**

Diagramas de Transição

- **then** e **else**
  - Já está sendo coberto pelo autômato da 1 estratégia (**palavras reservadas como identificadores**)
  - **2 estratégia:**

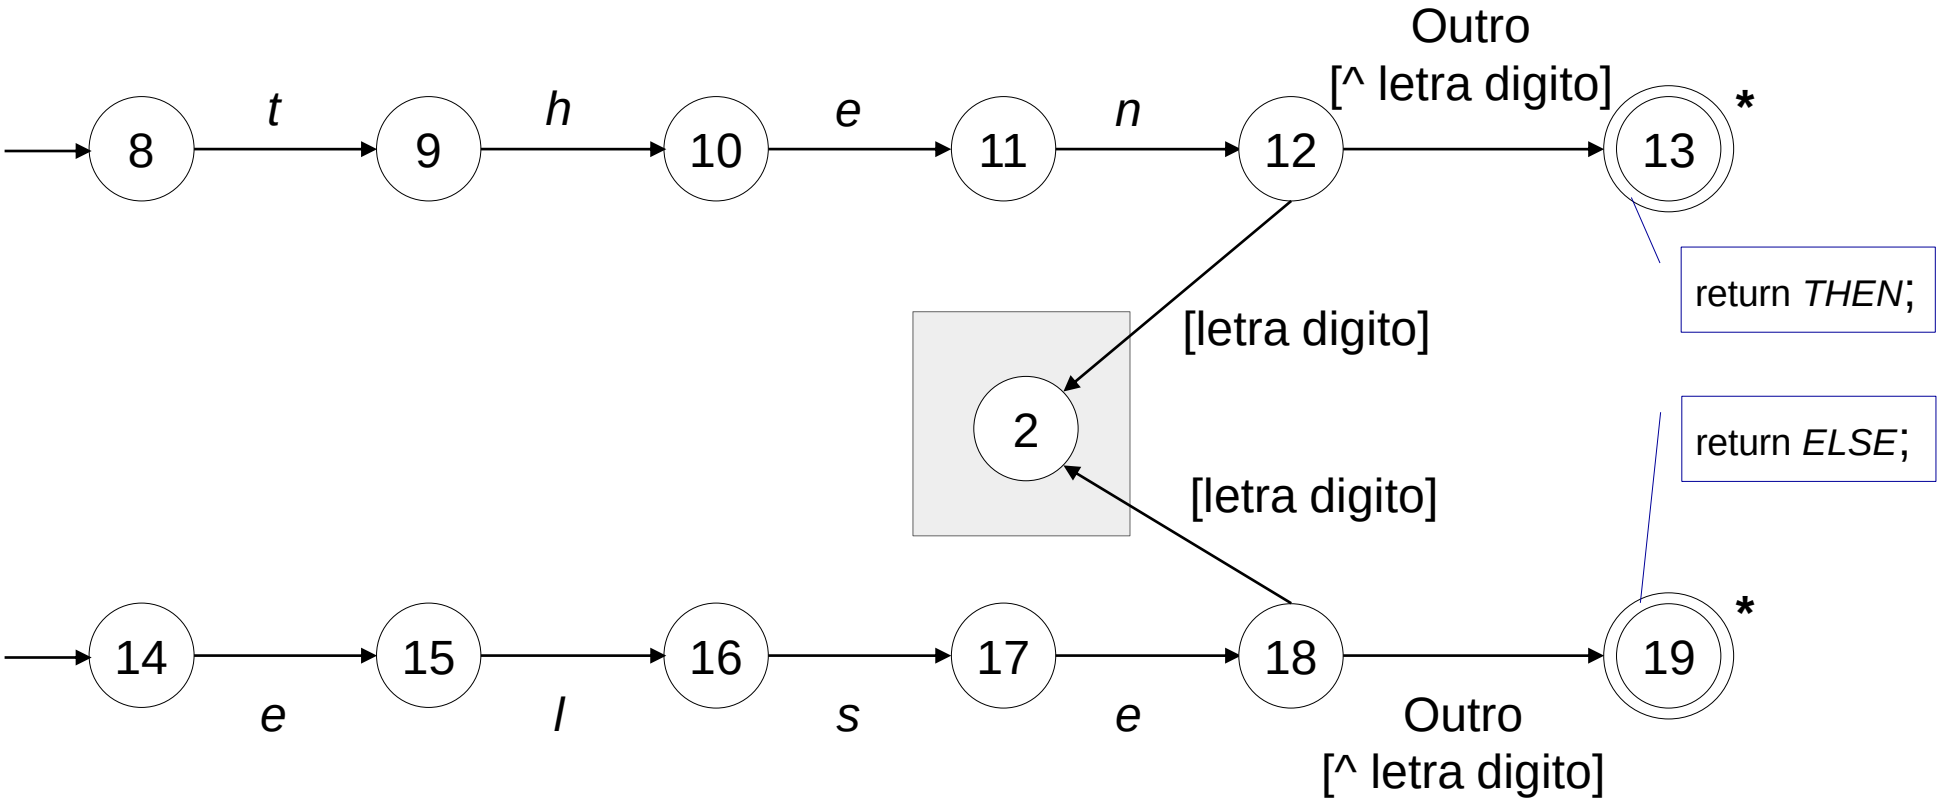

Diagramas de Transição

- **ws (separadores)**
  - Espaços em branco, tabulações e quebras de linha

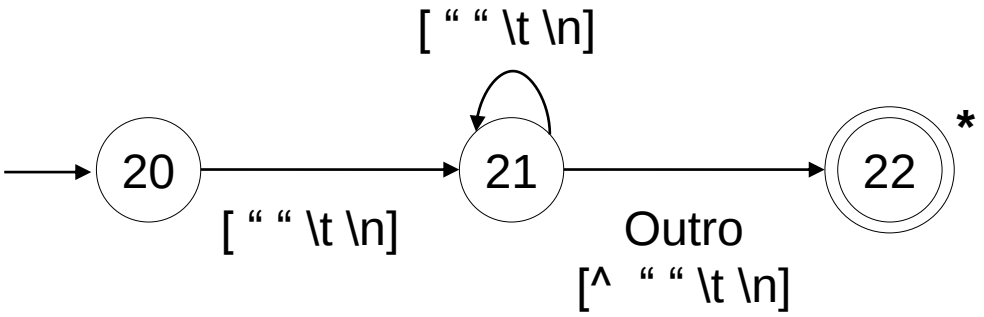

Diagramas de Transição

- **Número**
  - ***numero*** → *digitos* (*.digitos*) ? *(*E[+ -] ? *digitos*) ?

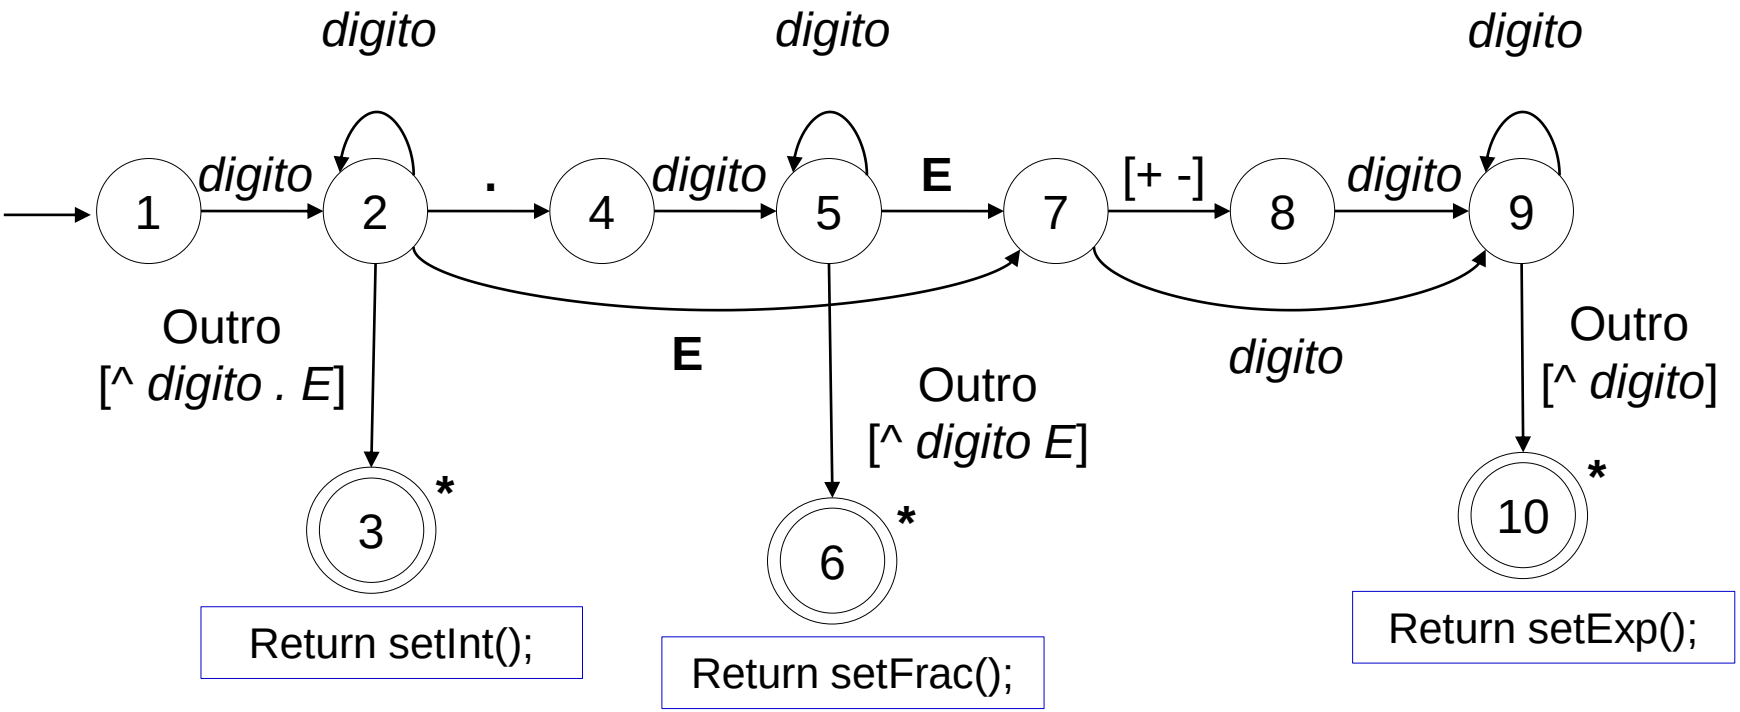

Exercícios

- Faça o diagrama de transição para reconhecer as expressões regulares:
  - (a|b)* a (a|b)(a|b)
  - a*ba*ba*ba*
  - (aa|bb)* ((ab|ba)(aa|bb)* (ab|ba)(aa|bb)*)*
- Defina a expressão regular e o diagrama de transição para lidar com comentários em C:
  - **Comentários de linha** (**ex:** *// comentário \n*)
  - **Comentários de blocos** (**ex:** */* comentário */*)

FORMAS DE IMPLEMENTAÇÃO

Tabela de Símbolos

- Forma de implementação da estrutura de representação dos *tokens* afeta a memória usada pela tabela de símbolos
  - Operadores podem ser representados por 2 caracteres
  - Palavras reservadas geralmente não são grandes
    - Também podem ser representadas por **códigos**
  - **Como lidar com identificadores, números e *strings*?**

  - **Alocação estática:**
    - **Vantagem:** implementação mais simples
    - **Desvantagem:** desperdício de memória

  - **Alocação dinâmica:**
    - **Vantagem:** uso otimizado de memória
    - **Desvantagem:** exige um controle mais elaborado

Tabela de Símbolos

- Desempenho do analisador é influenciado pela **eficiência da consulta** a tabela de símbolos

  - **Busca linear:**
    - **Mais simples** de implementar
    - Pior desempenho (***O(n)***)
  - **Busca binária:**
    - Boa eficiência (***O(log n)***)
  - ***Hashing*:**
    - Ideal para consulta a palavras reservadas (***O(1)***)
    - Garante acesso **sem colisões** (palavras já são conhecidas)

Diagramas de Transição

- Formas de implementação **manual** de um código para **simular o comportamento de um diagrama**:
  - Solução a*d hoc*
  - Codificação direta do autômato finito
  - Uso de tabela de transição

- Implementação **automática** do código:
  - Muito usado em **projetos reais**
  - Geralmente adotam **métodos dirigidos por tabela**
  - **Ex:** Lex, JavaCC

Solução *Ad Hoc*

- Implementação focada no **fluxo de entrada**
  - **Simples e fácil**

- Estados do autômato são implementados **implicitamente**
  - **Aninhamento de IF's** define as **mudanças de estado**
    - Aninhamentos implementam a **derivação de um lexema aceito**
    - Mesma **transição é repetida** em diferentes partes do código

- Complexidade do código cresce com o **Nro. de estados**
  - Aplicável a autômatos com **poucos estados**

- **Implementação personalizada**
  - Código sensível a mudanças no autômato

Exemplo (*Ad Hoc*)

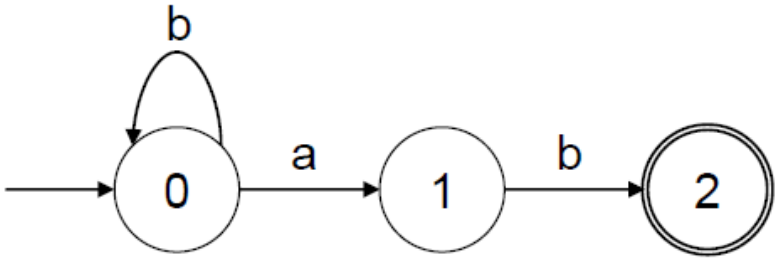


```
Inicio {s0}
char c ← prox_char()
se (c = "b") então
    c ← prox_char()
    enquanto (c = "b") faça
        c ← prox_char()
    fim enquanto
senão
Fim
```

```
{*** bloco repetido ***}
se (c = "a") então {s1}
    c ← prox_char()
    se ( c = "b" e  prox_char() = EOF ) então {s2}
        retorna "cadeia aceita"
    senão
        retorna "cadeia rejeitada"
senão
    retorna "cadeia rejeitada"
```

Retirado de [Aluisio, 2011]

Exemplo (*Ad Hoc*)

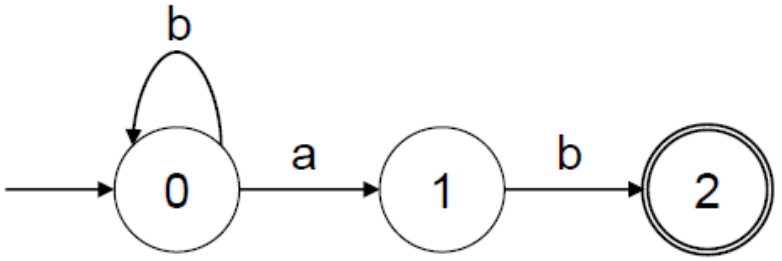

Inicio ***{s0}***

char c ← prox_char()

*enquanto (**c = "b"**) faça*

c ← prox_char()

fim enquanto

*se (**c = "a"**) então **{s1}***

c ← prox_char()

*se (**c = "b"** e prox_char() = EOF) então **{s2}***

retorna "cadeia aceita"

senão

retorna "cadeia rejeitada"

senão

retorna "cadeia rejeitada"

Fim

Codificação Direta

- Reflete diretamente o **autômato finito**

- Estados do autômato são implementados **explicitamente**
  - **Estado atual** é armazenado em uma **variável**

- **Incorpora as transições no código** do programa
  - **Verificação externa** trata o **estado corrente**
    - Leva ao código para cada um dos possíveis estados
  - **Verificação interna** trata o **símbolo lido**
    - Implementa as ações de um estado
    - Envolve mudanças de estado e leitura do próximo caractere da entrada

- Ainda é uma **implementação personalizada**
  - Código permanece sensível a mudanças no autômato

Exemplo (*Codificação Direta*)

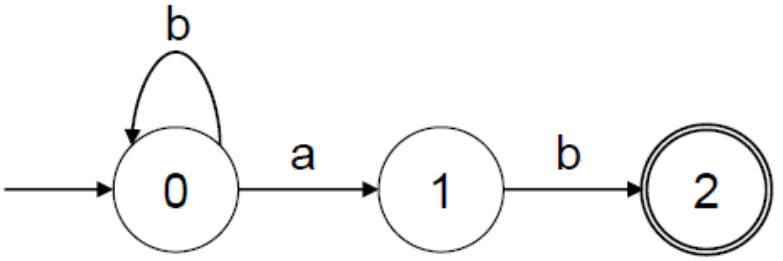


```
Inicio
s ← 0 {estado 0}
enquanto ( s = 0 ou s = 1 ) faça
    c ← prox_char()
    caso (s) seja

    fim caso
fim enquanto
c ← prox_char()
se (s = 2 e c = EOF) então
    retorna "cadeia aceita"
senão
    retorna "cadeia rejeitada"
Fim
```

```
0: se (c = a) então
        s ← 1 {estado 1}
   senão
        se (c = b) então
            s ← 0 {estado 0}
        senão
            retorna "cadeia rejeitada"
1: se (c = b) então
        s ← 2  {estado 2}
   senão
            retorna "cadeia rejeitada"
```

Retirado de [Aluisio, 2011]

Exemplo (*Codificação Direta*)

RELOP e GT *são códigos definidos por* **#define ou enum**

Retirado de [Aho, 2008]

```
// Código para o diagrama do RELOP
Token * getRelop() {
   Token * tk = (Token *) malloc(sizeof(Token));
    tk.nome = RELOP;
    // Processa entrada até encontrar token ou falhar
    while (1) {
        switch (state) {
            case 0 : { c = nextChar();
                if ( c == '<' ) state = 1;
                else if ( c == '=' ) state = 5;
                else if ( c == '>' ) state = 6;
                else fail(); // Lexema não é um relop
                break; }
            ...
            case 1 : {...}
            ...
            case 8 : {
                prox--; // Retrocede prox
                tk.atributo = GT;
                return tk; }
        } // Fim do switch
    } // Fim do while
} // Fim da função
```

Tabela de Transição

- Autômato representado como uma **estrutura de dados**
  - **Tipo Abstrato de Dados (TAD)**
  - **Atributos:** descrevem as características do autômato finito
    - **Conjunto de transições** representado por uma **tabela**
    - Deve indicar o **estado inicial e os finais**
    - Precisa representar as **entradas não previstas** em um estado
  - **Operações:** possibilitam acesso aos atributos do TAD
- Permite a implementação de um **código genérico**
  - Especificidades do autômato estão **restritas ao TAD**

Exemplo (Tabela de Transição)

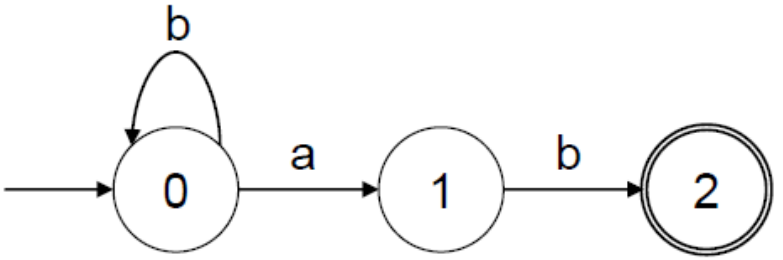

Modelo Conceitual

	Estados	Símbolos Entrada	
		a	***b***
➡	***0***	{1}	{0}
	1	–	{2}
*	***2***	–	–

Possível Implementação

Estado	Final	Símbolos Entrada		
		a	***b***	***outros***
0	***N***	{1}	{0}	{-1}
1	***N***	{-1}	{2}	{-1}
2	***S***	{-1}	{-1}	{-1}
-1	***N***	{-1}	{-1}	{-1}

$S_0 = 0$

Função completa: usa **estado extra** (**estado de erro**) para tratar **entradas não prevista**

Retirado de [Aluisio, 2011]

Exemplo (Tabela de Transição)

Inicio

s ← S_0 ***{estado inicial}***

c ← prox_char()

enquanto (c ≠ EOF e ***final(s)*** *= 0 e* ***s ≠ -1****) faça*

s ← ***move(s, c)***

c ← prox_char()

fim enquanto

*se (****final(s)*** *= 1) então*

retorna “cadeia aceita”

senão

retorna “cadeia rejeitada”

Fim

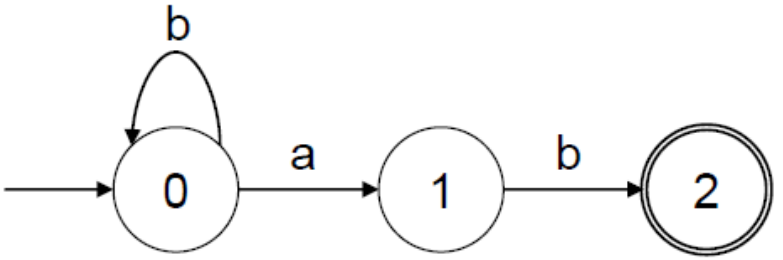

Possível Implementação

Estado	Final	Símbolos Entrada		
		a	***b***	***outros***
0	***N***	{1}	{0}	{-1}
1	***N***	{-1}	{2}	{-1}
2	***S***	{-1}	{-1}	{-1}
-1	***N***	{-1}	{-1}	{-1}

S_0 = 0

Retirado de [Aluisio, 2011]

Exemplo (Tabela de Transição)

Inicio

s ← S_0 ***{estado inicial}***

c ← prox_char()

enquanto (c ≠ EOF e ***final(s)*** *= 0 e* ***s ≠ -1****) faça*

s ← ***move(s, c)***

c ← prox_char()

fim enquanto

*se (****final(s)*** *= 1) então*

retorna “cadeia aceita”

senão

retorna “cadeia rejeitada”

Fim

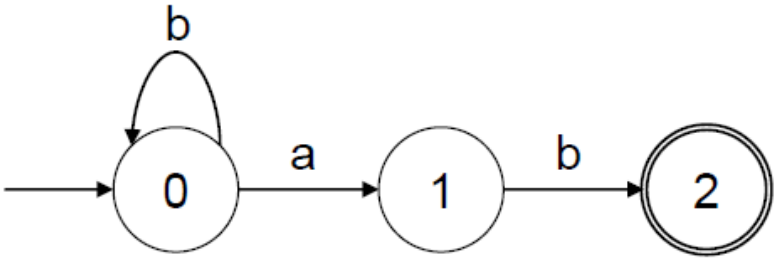

Possível Implementação

Estado	Final	Símbolos Entrada		
		a	***b***	***outros***
0	***N***	{1}	{0}	{-1}
1	***N***	{-1}	{2}	{-1}
2	***S***	{-1}	{-1}	{-1}
-1	***N***	{-1}	{-1}	{-1}

S_0 = 0

Código funciona bem se o autômato finito for determinista (AFD)

Retirado de [Aluisio, 2011]

Tabela de Transição

- **Vantagens:**
  - Código reduzido (**elegância**)
  - Mesmo código atende a várias linguagens (**generalidade**)

- **Desvantagem:**
  - **Tabelas estáticas:** pode demandar/desperdiçar **muito espaço de memória**
    - Alfabeto grande ou autômato com muitos estados no autômato
  - **Tabelas dinâmicas:** torna o **processamento mais lento**

Análise Baseada em Diagramas

- Analisador léxico precisa **executar o código de todos os diagramas** para determinar o *token* a ser retornado

- **Possíveis estratégias:**
  - Executar os diagramas **sequencialmente**
  - Executar os diagramas **em paralelo**
  - **Combinar todos os diagramas** em um único

Execução Sequencial

- *Tokens* são verificados em sequência
  - Permite **diagramas específicos** para palavras-chave
  - Ordem de execução define a **prioridade de reconhecimento** entre os *tokens*
    - **Ex:** palavras-chave vs. identificadores

- **Falha** no percorrimento de um diagrama provoca **troca de diagrama**
  - Reinicialização do campo ***prox***
  - Inicialização do próximo diagrama

Execução Paralela

- *Tokens* são analisados ao mesmo tempo
  - Caractere é tratado por **todos diagramas ativos**
    - **Diagrama ativo:** capaz de processar a entrada
  - Cada diagrama controla suas transições
    - **Se** símbolo está previsto **então** realiza a transição

      Senão desativa o diagrama

- Precisa de regras para **tratar ambiguidades**
  - **Define o que fazer** quando um padrão é atendido mas ainda existem outros diagramas ativos
    - **Ex:** *thenext* ou *then* ? “->” ou “-” ? “<=” ou “<” ?
  - Estratégia mais usual é **pegar o lexema mais longo**
    - Uso de **palavra reservada** para priorizar palavras-chave

Diagrama Combinado

- **Todos os diagramas representados em um só**

- Diagrama gerado deve:
  - Ler entrada **até não existir transição possível**
  - Retornar **lexema mais longo** que casou com um padrão

- **Tarefa é geralmente complexa:**
  - **Problema:** tratar diagramas com a **mesma transição**
  - **Solução:** usar um **autômato finito não determinístico com transições ε (AFNDε)**

GERADORES AUTOMÁTICOS DE ANALISADORES LÉXICOS (LEX / FLEX)

Geradores Automático

- **Gerador de analisadores léxicos** [Alexandre, 2014]:

*"Programa que **recebe como entrada a especificação léxica** para uma linguagem e **produz como saída um programa que faz a análise léxica** dessa linguagem"*

- **Por que usar um gerador de analisadores?**
  - **Menos trabalho**
  - Garante a geração de um **analisador léxico correto**

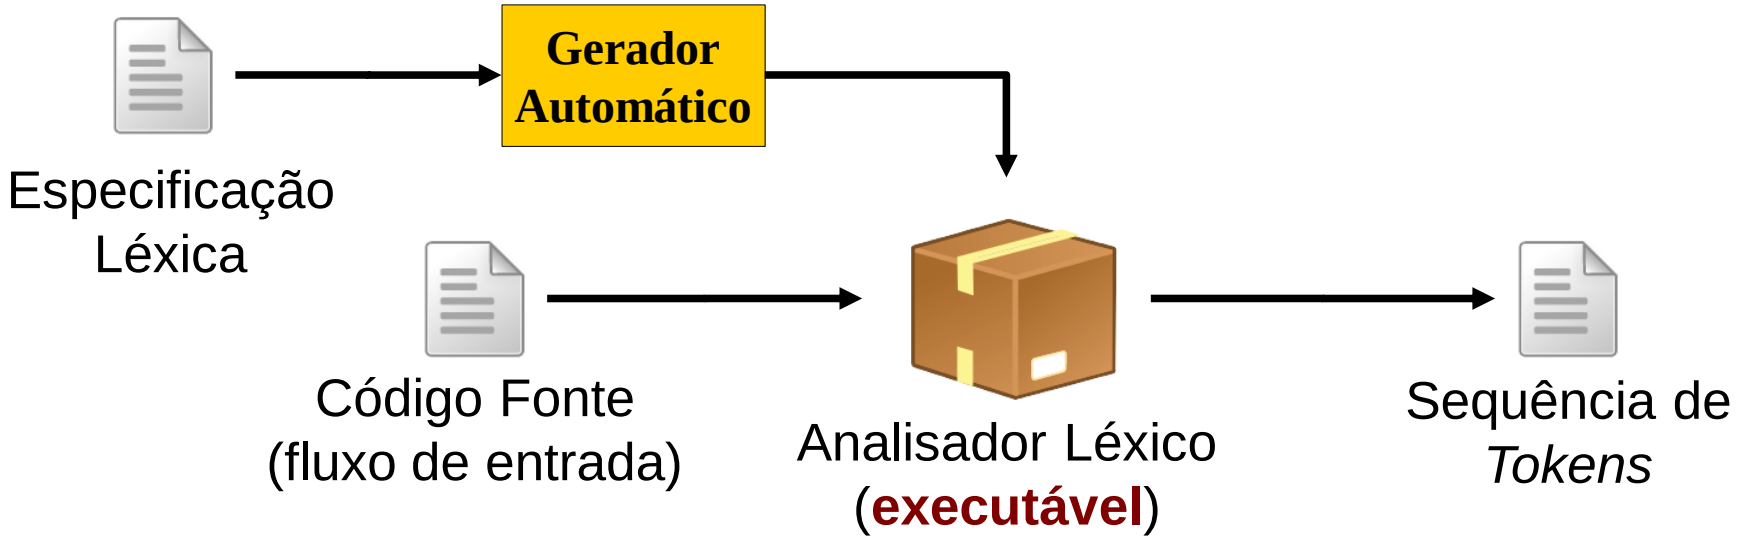

Gerador Automático Flex

- **Flex** (*Fast Lexical Analyzer Generator*)
  - Versão GNU do gerador Lex (**software livre**)

- **Especificação léxica** envolve a descrição dos padrões para os *tokens* (**expressões regulares**)
  - Usa notação da **linguagem Lex** (**arquivo *.l ou .lex***)

- **Compilador Lex** gera um **programa que simula o diagrama de transição** criado a partir dos padrões
  - Programa gerado em **linguagem C**
  - **Sintaxe:** *flex -o lexer.c lexer.lex*

- **Compilador C** usado para gerar o **código executável**
  - **Ex:** *gcc -o lexer lexer.c*

Gerador Automático Flex

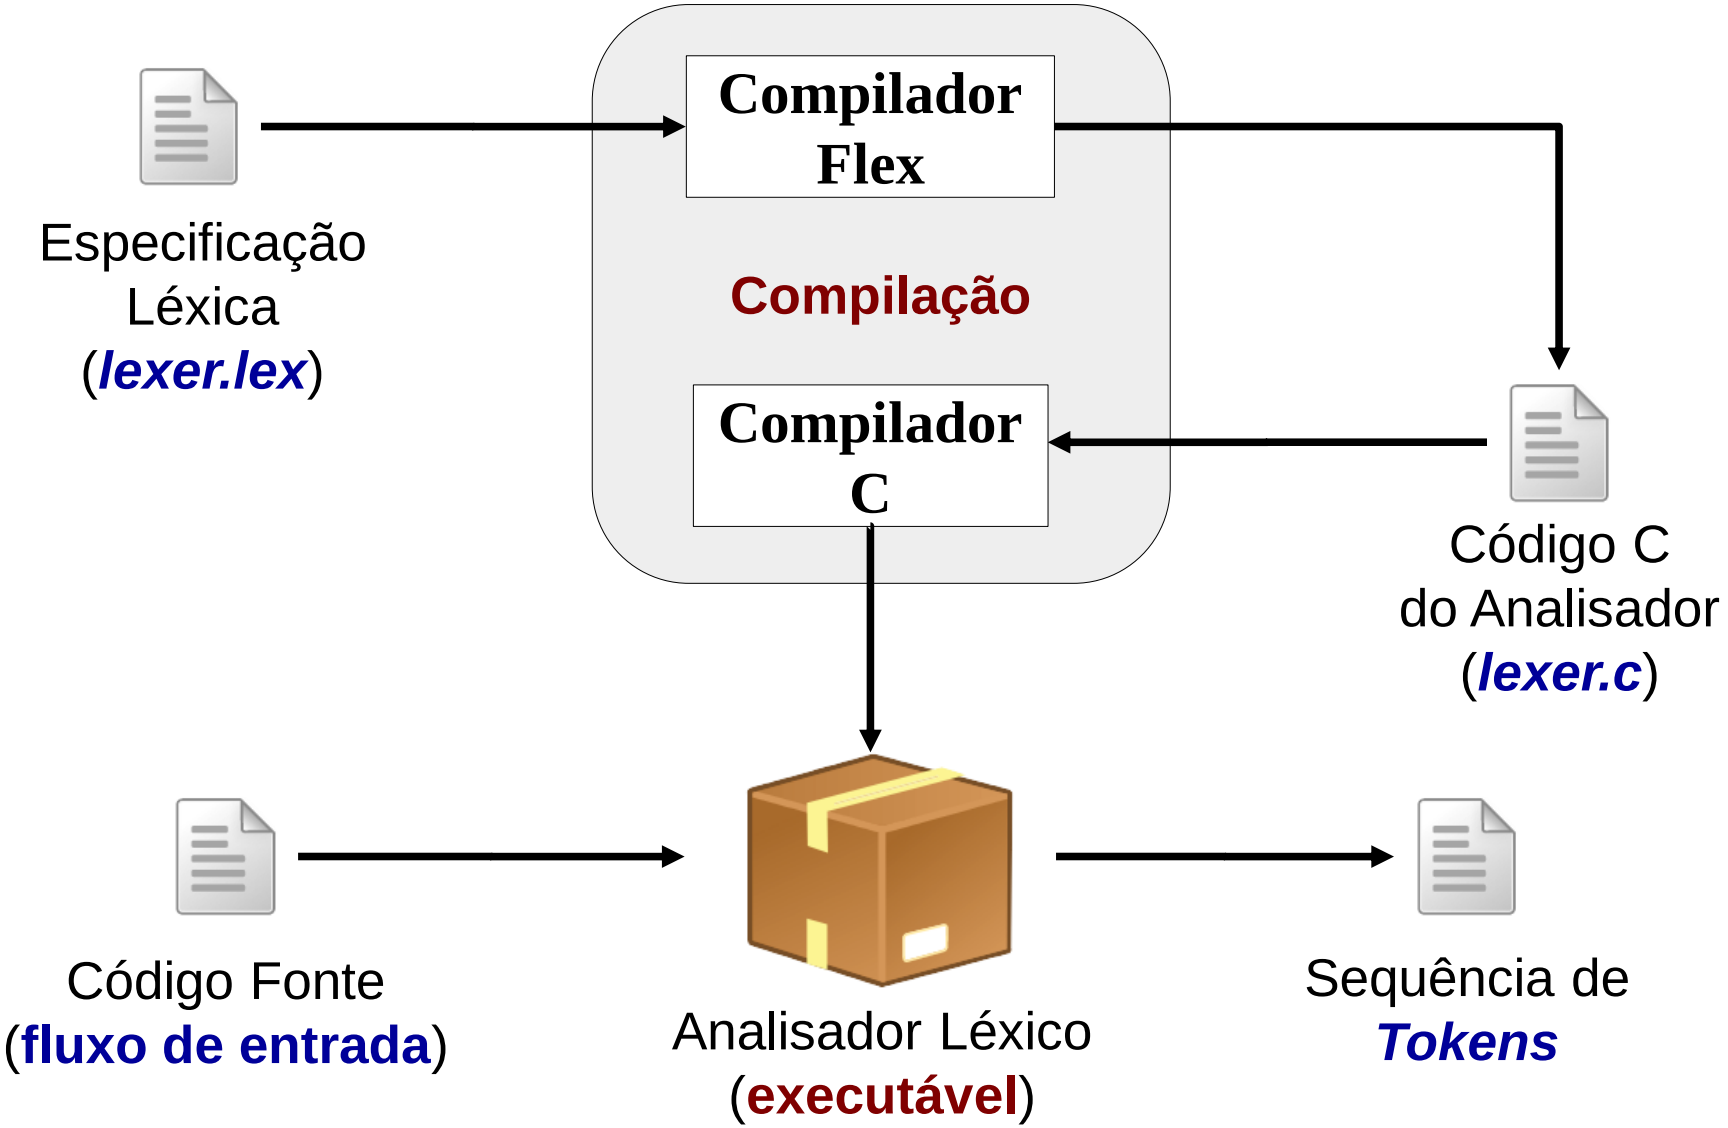

Estrutura de Programas Lex

- Especificação é dividida em 3 partes:

Declarações

%%

Regras de tradução

%%

Código

Estrutura de Programas Lex

- **Declarações:** especifica variáveis globais, constantes manifestas e definições regulares
  - **Constantes manifestas:**
    - Identificadores para constantes (**ex:** nome dos *tokens*)
    - Conjunto de diretivas ***#define*** do C
  - **Definições regulares:**
    - Expressões regulares usadas como símbolos pelos padrões
  - Variáveis e constantes manifestas são declaradas dentro de **delimitadores especiais *%{* e *%}***
    - Copia o conteúdo diretamente para o arquivo ***lex.yy.c***

Estrutura de Programas Lex

- **Regras de tradução:** especifica os padrões e suas ações
  - **Parte principal** da especificação léxica (**única obrigatória**)

- **Sintaxe:** *padrão { ação }*
  - **Padrão:** expressão regular que descreve um *token* da linguagem
  - **Ação:** fragmento de código C que determina o que fazer quando um lexema casa com o padrão especificado
    - **Mais comum:** instanciar um *token* para o lexema encontrado
    - Pode utilizar funções auxiliares descritas na seção código ou arq. externo

- **Código:** especifica funções auxiliares usadas nas ações
  - Também podem ser especificadas em **arquivos separados**
  - Geralmente usadas para **manipular a tabela de símbolos**

Exemplos de Padrões do Flex

Padrão	**Descrição Informal**
[0-9]	Qualquer dígito entre 0 e 9
[0+9]	0, + ou 9
[0,9]	0, ‘, ‘ ou 9
[0 9]	0, ‘ ‘ ou 9
[-0-9]	- ou qualquer dígito entre 0 e 9
[0-9]+	1 ou mais dígitos entre 0 e 9
a?	Indica opcionalidade: (a | ε)
[^a]	Qualquer caractere, exceto ‘a‘
[^A-Z]	Qualquer outro caractere, exceto as letras maiúsculas
^aba	Ocorrência de 'aba' no início de uma linha
aba$	Ocorrência de 'aba' no final de uma linha
a{2, 4}	‘aa‘, ‘aaa‘ ou ‘aaaa‘
a{2, }	2 ou mais ocorrências de ‘a‘
a{4}	Exatamente 4 a’s, ou seja, ‘aaaa‘
.	Qualquer caractere, exceto *newline*
a*	0 ou mais ocorrências de ‘a‘
a+	1 ou mais ocorrências de ‘a‘
[a-z]	Qualquer letra minúscula
[a-zA-Z]	Qualquer letra do alfabeto (minúscula ou maiúscula)
w(x | y)z ou w[xy]z	‘wxz‘ ou ‘wyz‘
\□, com □ ∈ {. , ^, +, ?, etc.}	Ocorrência do caractere □ no padrão
\□, com □ ∈ {0 , n, t, etc.}	Ocorrência de caractere especial do C (\0, \n, \t, etc.)
<<EOF>>	fim de arquivo

Estrutura de Programas Lex

- Quando **nenhum padrão for casado**, uma regra padrão do Flex **imprime os caracteres não reconhecidos**

- **Precedência na solução de conflitos:**
  1. Preferência pelo **prefixo mais longo**
  2. **Ordem de descrição dos padrões** no programa Lex

- **Operador *lookahead*:**
  - **Padrão:** sempre **lê o próximo caractere** após o casamento do padrão **e depois recua a entrada** para consumir apenas o lexema
  - O que fazer quando o casamento exige que o padrão seja seguido por um certo conjunto de caracteres?
    - **Solução:** uso da barra condicional (*/*)
    - Inclui um **padrão adicional** após a barra que **não faz parte do lexema**

Estrutura de Programas Lex

- **Exemplo:** **IF / \(.* \) {letter}**

  - Padrão permite diferenciar o comando *IF* de uma variável indexada *IF(x,y)* no Fortran
    - IF(I,J) = 3
    - IF (condição) THEN

  - Necessita que a entrada seja pré-processada para a remoção dos espaços em branco

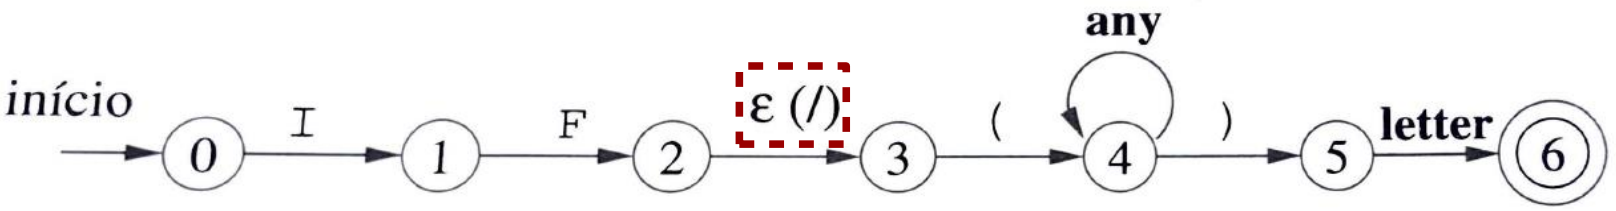

AFND do IF

Integração com o Programa Usuário

- O analisador léxico gerado a partir de um programa *lex* possui as seguintes características:
  - Usa a rotina ***yylex( )*** para chamada do analisador pelo usuário
    - Não possui argumento de entrada e retorna um **inteiro** (padrão)
      - Retorno geralmente é associado pelo usuário ao **tipo do *token***
      - Tipo do retorno pode ser alterado por um **tipo definido pelo usuário**
  - Interface realizada por **2 variáveis globais do tipo FILE**:
    - Entrada é lida do arquivo endereçado por ***yyin***
      - Padrão é o ponteiro ***stdin*** (teclado)
    - Resultado é enviado para o arquivo endereçado por ***yyout***
      - Padrão é o ponteiro ***stdout*** (tela)
    - Ambas podem ser modificadas na **seção de código do prog. *lex***
  - Variável ***yytext*** aponta para a última cadeia reconhecida
    - **Variável global** do tipo ponteiro para caracteres (***string***)

Exemplo de um Programa Flex

Fonte: *https://www.geeksforgeeks.org/flex-fast-lexical-analyzer-generator/*

```
/* Declare Section has one variable which can
    be accessed inside yylex() and main() */

%{
    int count = 0;
%}

%%

/* Rule Section has 3 rules:
1- matches with capital letters
2- matches with any character except newline
3- does not take input after the enter */

[A-Z] {printf("%s capital letter\n", yytext); count++;}
.     {printf("%s not a capital letter\n", yytext);}
\n    {return 0;}

%%
```

```
/* Code Section prints the number of
capital letter present in the given input */

int yywrap(){}

int main(){

// Code to take input from file
// FILE *fp;
// char filename[50];
// printf("Enter the filename: \n");
// scanf("%s",filename);
// fp = fopen(filename,"r");
// yyin = fp;

yylex(); // lexer call (runs Rule Section)

printf("\nNumber of Captial letters "
"in the given input - %d\n", count);

return 0;

}
```

Exemplo de um Programa Flex

Fonte: *https://www.geeksforgeeks.org/flex-fast-lexical-analyzer-generator/*

```
/* Declare Section has one variable which can
    be accessed inside yylex() and main() */

%{
    int count = 0;
%}

%%

/* Rule Section has 3 rules:
1- matches with capital letters
2- matches with any character except newline
3- does not take input after the enter */

[A-Z] {printf("%s capital letter\n", yytext); count++;}
.     {printf("%s not a capital letter\n", yytext);}
\n    {return 0;}

%%
```

- **yytext:** o lexema encontrado
- **yyin:** ponteiro de arquivo para a entrada
- **yylex():** função principal do flex
- **yywrap():** função que define se a análise continua (0) ou não (1) ao encontrar EOF

```
/* Code Section prints the number of
capital letter present in the given input */

int yywrap(){}

int main(){

// Code to take input from file
// FILE *fp;
// char filename[50];
// printf("Enter the filename: \n");
// scanf("%s",filename);
// fp = fopen(filename,"r");
// yyin = fp;

yylex(); // lexer call (runs Rule Section)

printf("\nNumber of Captial letters in the
given input - %d\n", count);

return 0;

}
```

Exemplo de um Programa Flex

```
shivani@workspace:~/Desktop/Compiler$ lex rough.l
shivani@workspace:~/Desktop/Compiler$ gcc lex.yy.c
shivani@workspace:~/Desktop/Compiler$ ./a.out
GFG123gfg
G capital letter
F capital letter
G capital letter
1 not capital letter
2 not capital letter
3 not capital letter
g not capital letter
f not capital letter
g not capital letter

Number of Captial letters in the given input - 3
```

Fonte: *https://www.geeksforgeeks.org/flex-fast-lexical-analyzer-generator/*

Exemplo de um Programa Flex

Fonte: *https://www.geeksforgeeks.org/flex-fast-lexical-analyzer-generator/*

```
/*** Declare Section***/

%option noyywrap

/* Define 2 counters */
%{
int nLines = 0; /* Nr. of lines */
int nChars = 0; /* Nr. of lines */
%}

%% /*** Rule Section ***/

\n  ++nLines;  /* counts lines */
.    ++nChars; /* counts chars */
end  return 0; /* stop */
```

```
%%  /*** User Section***/

int main(int argc, char **argv) {

yylex(); // lexer call
printf("Lines = %d, Chars = %d\n",
nLines, nChars );

return 0;
}
```

Exemplo de um Programa Flex

Fonte: *https://www.geeksforgeeks.org/flex-fast-lexical-analyzer-generator/*

```
/*** Declare Section***/

%option noyywrap

/* Define 2 counters */
%{
int nLines = 0; /* Nr. of lines */
int nChars = 0; /* Nr. of lines */
%}

%% /*** Rule Section ***/

\n  ++nLines;  /* counts lines */
.    ++nChars; /* counts chars */
end  return 0; /* stop */
```

```
%%  /*** User Section***/

int main(int argc, char **argv) {

yylex(); // lexer call
printf("Lines = %d, Chars = %d\n",
nLines, nChars );

return 0;
}
```

- Indica que ***yywrap()* não será fornecida**
  - Irá parar quando encontrar EOF
- Similar ao **uso do flag -lfl** na compilação
  - Ligação com versão padrão da função ***yywrap()*** que sempre retorna 1

Exemplo de um Programa Flex

```
shubham@gfg-desktop:~$ lex lines.l
shubham@gfg-desktop:~$ gcc lex.yy.c
shubham@gfg-desktop:~$ ./a.out
Geeks
for
Geeks
end
number of lines = 3, number of chars = 13
shubham@gfg-desktop:~$
```

Fonte: *https://www.geeksforgeeks.org/flex-fast-lexical-analyzer-generator/*

Analisador Léxico no Flex

- **Ex:** analisador para expressões [Alexandre, 2014]
  - **Codificação em 3 arquivos** (**projeto de TAD**)
  - **Arquivo cabeçalho (*exp.h*):**
    - Contém as definições de tipos, das constantes e dos protótipos das funções
  - **Arquivo do Flex (*exp.lex*):**
    - Contém as **especificações dos padrões**
  - **Arquivo de usuário (*exp.c*):**
    - Simula o analisador sintático
    - Responsável pela **chamada do analisador léxico**

Analisador Léxico no Flex

Fonte: [Alexandre, 2014]

```
// Arquivo exp.h
// constantes booleanas
#define TRUE 1
#define FALSE 0
// constantes para nome de token
#define TOK_NUM 0
#define TOK_OP 1
#define TOK_PONT 2
#define TOK_ERRO 3
// constantes para operadores
#define SOMA 0
#define SUB 1
#define MULT 2
#define DIV 3
// constantes para parenteses
#define PARESQ 0
#define PARDIR 1


// estrutura de um token
typedef struct {
    int tipo;
    int valor;
} Token;
// funcao para criar um token
extern Token *token();
// funcao do analisador lexico
extern Token *yylex();
```

Analisador Léxico no Flex

Fonte: [Alexandre, 2014]

```
// Arquivo exp.h
// constantes booleanas
#define TRUE 1
#define FALSE 0
// constantes para nome de token
#define TOK_NUM 0
#define TOK_OP 1
#define TOK_PONT 2
#define TOK_ERRO 3
// constantes para operadores
#define SOMA 0
#define SUB 1
#define MULT 2
#define DIV 3
// constantes para parenteses
#define PARESQ 0
#define PARDIR 1

// estrutura de um token
typedef struct {
    int tipo;
    int valor;
} Token;
// funcao para criar um token
extern Token *token();
// funcao do analisador lexico
extern Token *yylex();
```

Mudança do tipo de retorno padrão

Analisador Léxico no Flex

Fonte: [Alexandre, 2014]

```
/* Arquivo exp.lex */
%option noyywrap
%option nodefault
%option outfile="lexer.c" header-file="lexer.h"
%{ #include "exp.h“ %}
NUM [0-9]+

%%
[[:space:]] { } /* ignora espaços */
{NUM} { return token(TOK_NUM, atoi(yytext)); }
\+ { return token(TOK_OP, SOMA); }
- { return token(TOK_OP, SUB); }
\* { return token(TOK_OP, MULT); }
\/ { return token(TOK_OP, DIV); }
\( { return token(TOK_PONT, PARESQ); }
\) { return token(TOK_PONT, PARDIR); }
/* Tratamento para token desconhecido */
. { return token(TOK_ERRO, 0); }

%%
// variavel global para um token
Token tok;
Token * token (int tipo, int valor) {
    tok.tipo = tipo;
    tok.valor = valor;
    return &tok;
}
```

Analisador Léxico no Flex

Fonte: [Alexandre, 2014]

```
/* Arquivo exp.lex */
%option noyywrap
%option nodefault
%option outfile="lexer.c" header-file="lexer.h"
%{ #include "exp.h“ %}
NUM [0-9]+

%%
[[:space:]] { } /* ignora espaços */
{NUM} { return token(TOK_NUM, atoi(yytext)); }
\+ { return token(TOK_OP, SOMA); }
- { return token(TOK_OP, SUB); }
\* { return token(TOK_OP, MULT); }
\/ { return token(TOK_OP, DIV); }
\( { return token(TOK_PONT, PARESQ); }
\) { return token(TOK_PONT, PARDIR); }
/* Tratamento para token desconhecido */
. { return token(TOK_ERRO, 0); }

%%
// variavel global para um token
Token tok;
Token * token (int tipo, int valor) {
    tok.tipo = tipo;
    tok.valor = valor;
    return &tok;
}
```

Analisador Léxico no Flex

Fonte: [Alexandre, 2014]

```
// Arquivo exp.c
#include "lexer.h"
#include "Expressao.h“
/* Le uma string como entrada */
YY_BUFFER_STATE buffer;
void inicializa(char *str) {
    buffer = yy_scan_string(str);
}
Token *proximo_token() {
    return yylex();
}
void imprime_token( Token *tok) {
…
}
```

```
int main(int argc, char **argv) {
    char entrada[200];
    Token *tok;
    printf("\nAnalise Lexica da expressao: ");
    fgets(entrada, 200, stdin);
    inicializa(entrada);
    tok = proximo_token();
    while (tok != NULL) {
        imprime_token(tok);
        tok = proximo_token();
    }
    return 0; }
```

Analisador Léxico no Flex

Fonte: [Alexandre, 2014]

```
// Arquivo exp.c
#include "lexer.h"
#include "Expressao.h“
/* Le uma string como entrada */
YY_BUFFER_STATE buffer;
void inicializa(char *str) {
    buffer = yy_scan_string(str);
}
Token *proximo_token() {
    return yylex();
}
void imprime_token( Token *tok) {
…
}
```

```
int main(int argc, char **argv) {
    char entrada[200];
    Token *tok;
    printf("\nAnalise Lexica da expressao: ");
    fgets(entrada, 200, stdin);
    inicializa(entrada);
    tok = proximo_token();
    while (tok != NULL) {
        imprime_token(tok);
        tok = proximo_token();
    }
    return 0; }
```

Analisador Léxico no Flex

- **Compilação no Flex:**
  - Gera os arquivos do analisador léxico (***lexer.c*** e ***lexer.h***)
  - Precisa indicar que está sendo usada uma declaração diferente para a função principal do analisador (***yylex***)
  - **Comando:**

flex ***-DYY_DECL="Token * yylex()"*** *exp.lex*

- **Compilação no C:**
  - Compila os arquivos dos analisadores léxico e sintático
  - Carrega os códigos objeto para gerar o executável
  - **Exemplo do comando:**

gcc -o exp lexer.c exp_flex.c

Analisador Léxico no Flex

- Entrada do Flex é um ponteiro para arquivo (***yyin***)
  - Valor é associado ao *stdin* (**entrada padrão**)

- **Leitura de um arquivo externo** é feita a partir da atribuição do seu endereço à variável ***yyin***

```
int inicializa (char *nome) {

    FILE *f = fopen(nome, "r");

    if (f == NULL)
        return FALSE;
    yyin = f;
    return TRUE;
}
```

Exercícios

1) Implemente manualmente um analisador léxico para cada um dos *tokens* utilizados para explicar os diagramas de transição, como segue:
   - **Palavras reservadas + Identificador:** *ad hoc*, autômato, tabela
   - **Palavras-chave (específico):** autômato, tabela
   - **Número:** autômato, tabela
   - **Relop:** *ad hoc*, tabela
   - **Separadores (*ws*):** *ad hoc*, tabela
   - **Comentários:** *ad hoc*, autômato, tabela
2) Junte as implementações (tabela) para criar um **único analisador léxico**. Faça um programa de teste que faz o papel do analisador sintático, ou seja, solicita um novo *token* e o apresenta na tela. Verifique se a sequência de *tokens* está de acordo com o código fonte dado como entrada
3) Escreva um programa em Flex que reconhece os padrões de CPF e e-mail. Como ação, ele deve indicar se foi digitado um CPF, um e-mail ou algo desconhecido
4) Gere um analisador léxico para os *tokens* do item 1 utilizando a ferramenta Flex

IMPLEMENTAÇÃO DO ANALISADOR LÉXICO

Geração Automática

- Geradores (Flex) **convertem as especificações léxicas em um diagrama de transição**
  - **Especificação:** usa notação para definir os padrões dos *tokens* (**expressões regulares**)
  - **Implementação:** simulação de **AFD** ou **AFND-ε**

- **AFND** é uma **representação abstrata** do algoritmo reconhecedor, enquanto que o **AFD** é um **algoritmo simples e concreto**
  - **AFND** facilita a geração do diagrama (**conversão**)
  - **AFD** facilita a simulação (**reconhecimento**)

Geração Automática

- Analisador léxico do Flex consiste:
  - Um **programa fixo** que **simula um autômato (genérico)**
  - Componentes criados a partir do programa Lex (**específico**):
    - **Tabela de transição** para o autômato
    - **Ações** a serem invocadas pelo simulador do autômato
    - **Funções auxiliares** passadas diretamente para a saída

- **Processo mecânico e sistêmico:**
  - Conversão das expressões regulares em AFNDs
  - Unificação dos AFNDs em um único autômato
  - Conversão do AFND em um AFD
  - Minimização do número de estados
  - Simulação do AFD

- Alternativa é **simular diretamente o AFND** gerado

Geração Automática

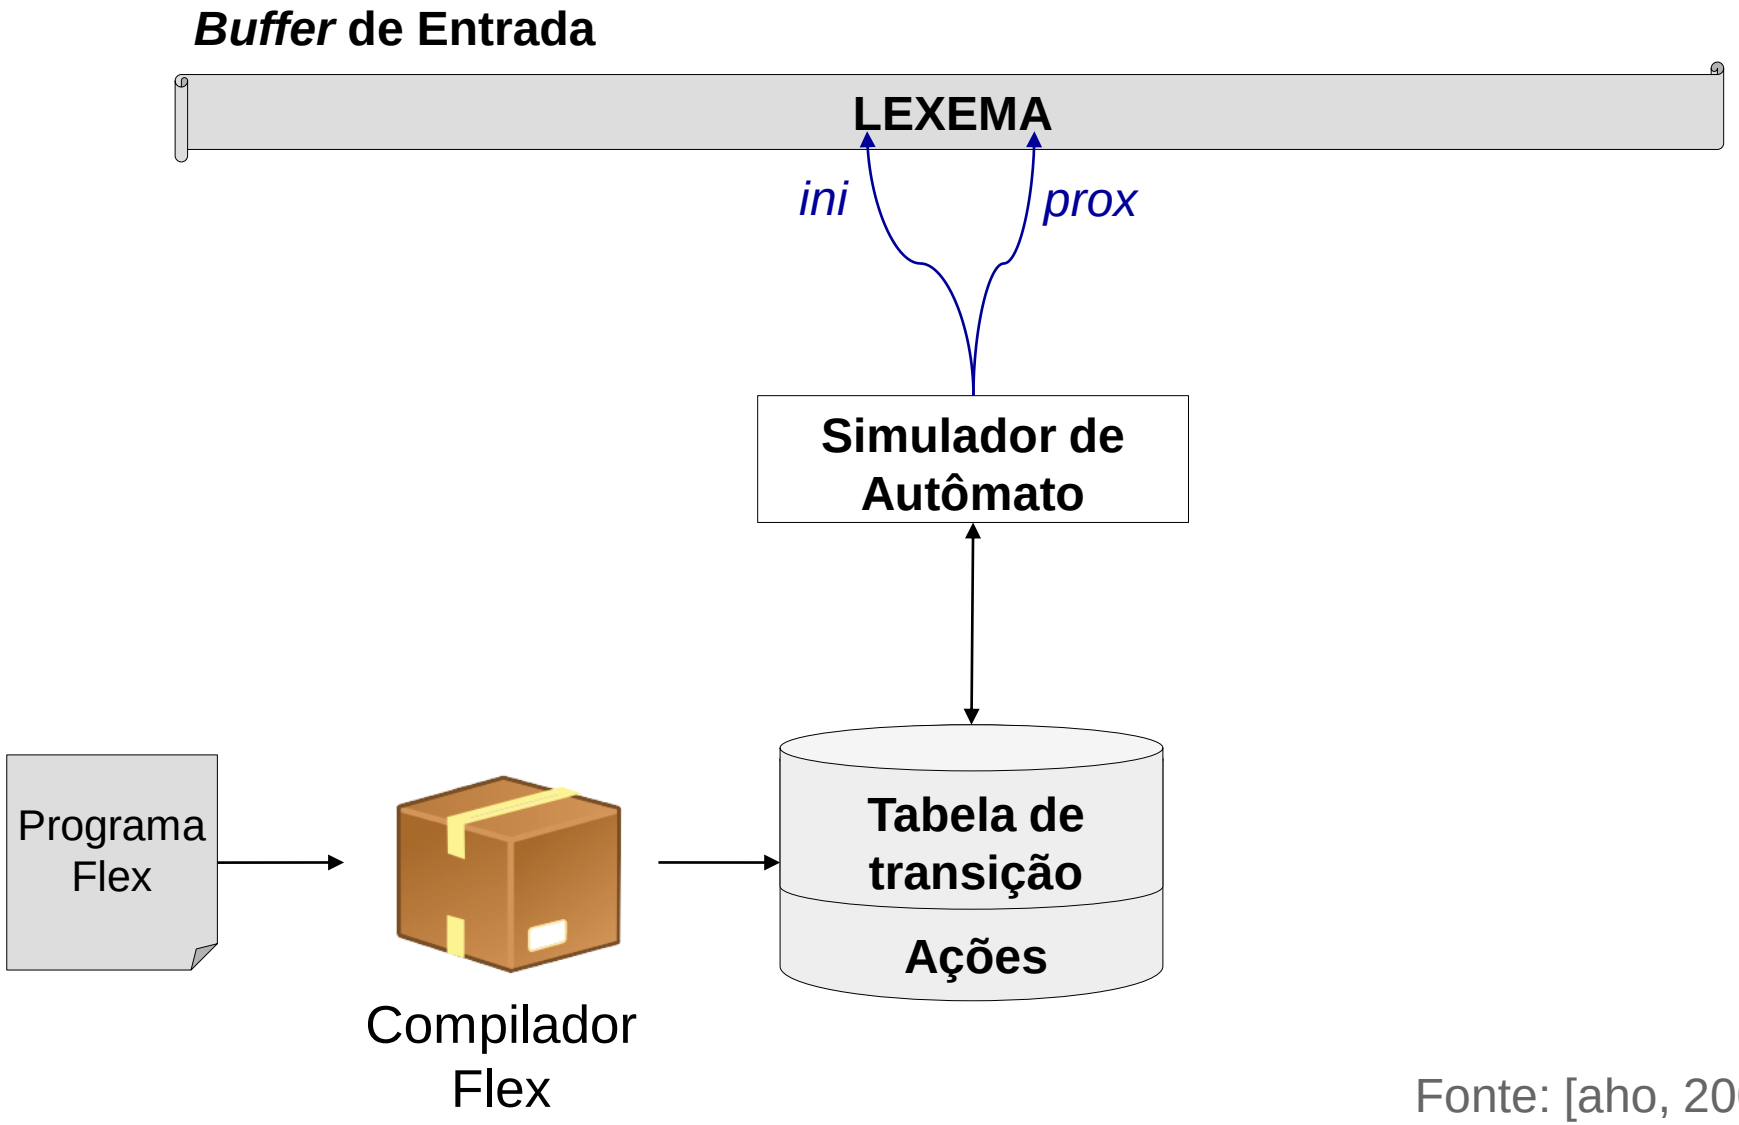

Fonte: [aho, 2008]

Conversão Expressões Regulares

- **Algoritmo de McNaughton-Yamada-Thompson:**
  - Gera AFND para reconhecer cadeias definidas na expressão regular
    - Algoritmo dirigido por sintaxe (produz a derivação para as expressões)
  - Baseado no **tratamento recursivo das relações elementares**:
    - **Base: símbolos do alfabeto**
    - **Passo recursivo: operações básicas** (concatenação, união e fecho)
  - Constrói um AFND para cada relação com um **único estado de aceitação**

- **Etapas:**
  - Decompor a expressão regular em suas relações elementares (**do todo para a parte**)
  - Construir um autômato finito que reconheça cada uma das subexpressões obtidas (**da parte para o todo**)

Conversão Expressões Regulares

Autômato *M*

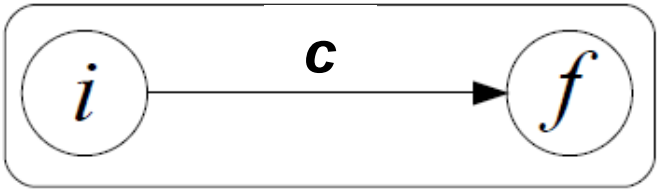

Reconhecimento do símbolo *c*

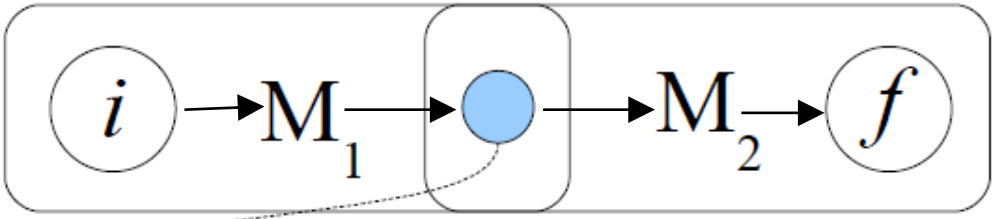

Concatenação

(estado final de M_1 e inicial de M_2)

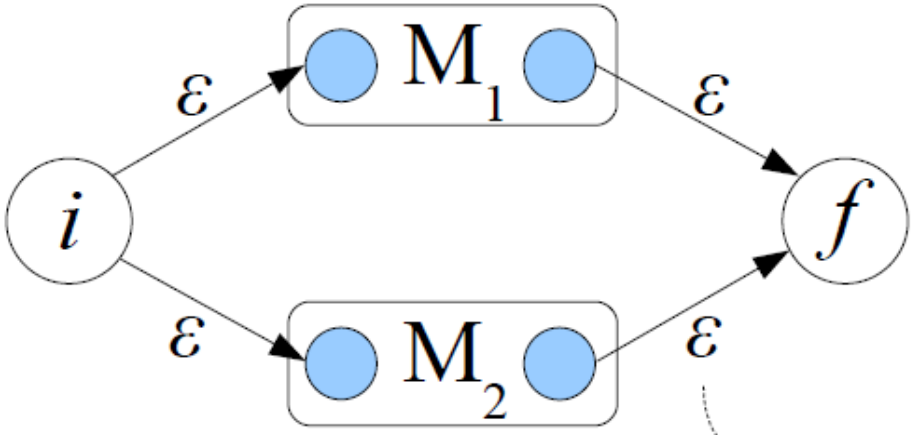

União

Movimento vazio

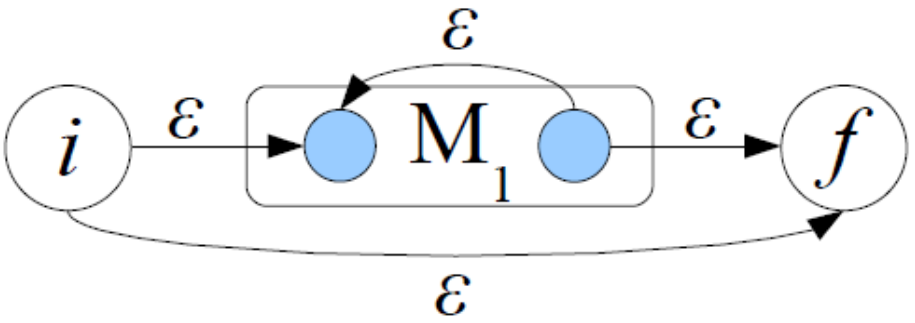

Fecho

Conversão Expressões Regulares

- **Exemplo:** considere ***R = (a|b)*abb***

Como seria um AFND desta expressão regular?

Conversão Expressões Regulares

- **Exemplo:** considere ***R = (a|b)*abb***
  - ***1 Passo:*** autômato para reconhecimento dos símbolos do alfabeto

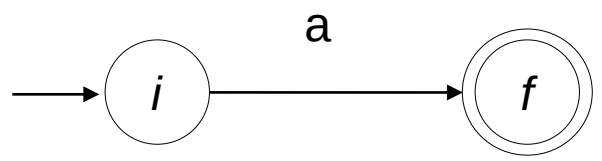

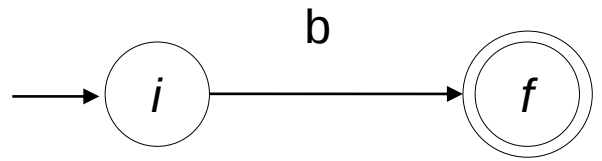

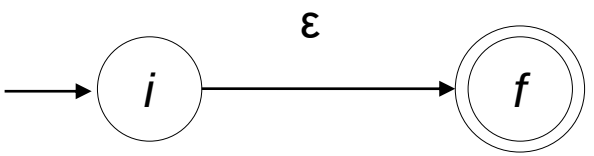

(Movimento vazio)

Conversão Expressões Regulares

- **Exemplo:** considere ***R = (a|b)*abb***
  - ***2 Passo:*** operação de união

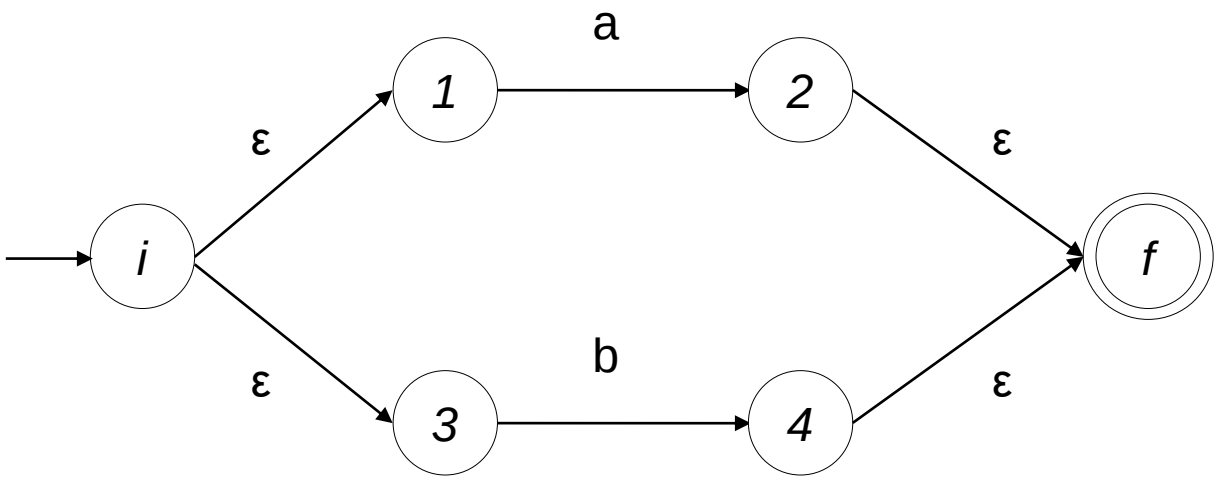

Conversão Expressões Regulares

- **Exemplo:** considere ***R = (a|b)*abb***
  - ***3 Passo:*** operação de fecho

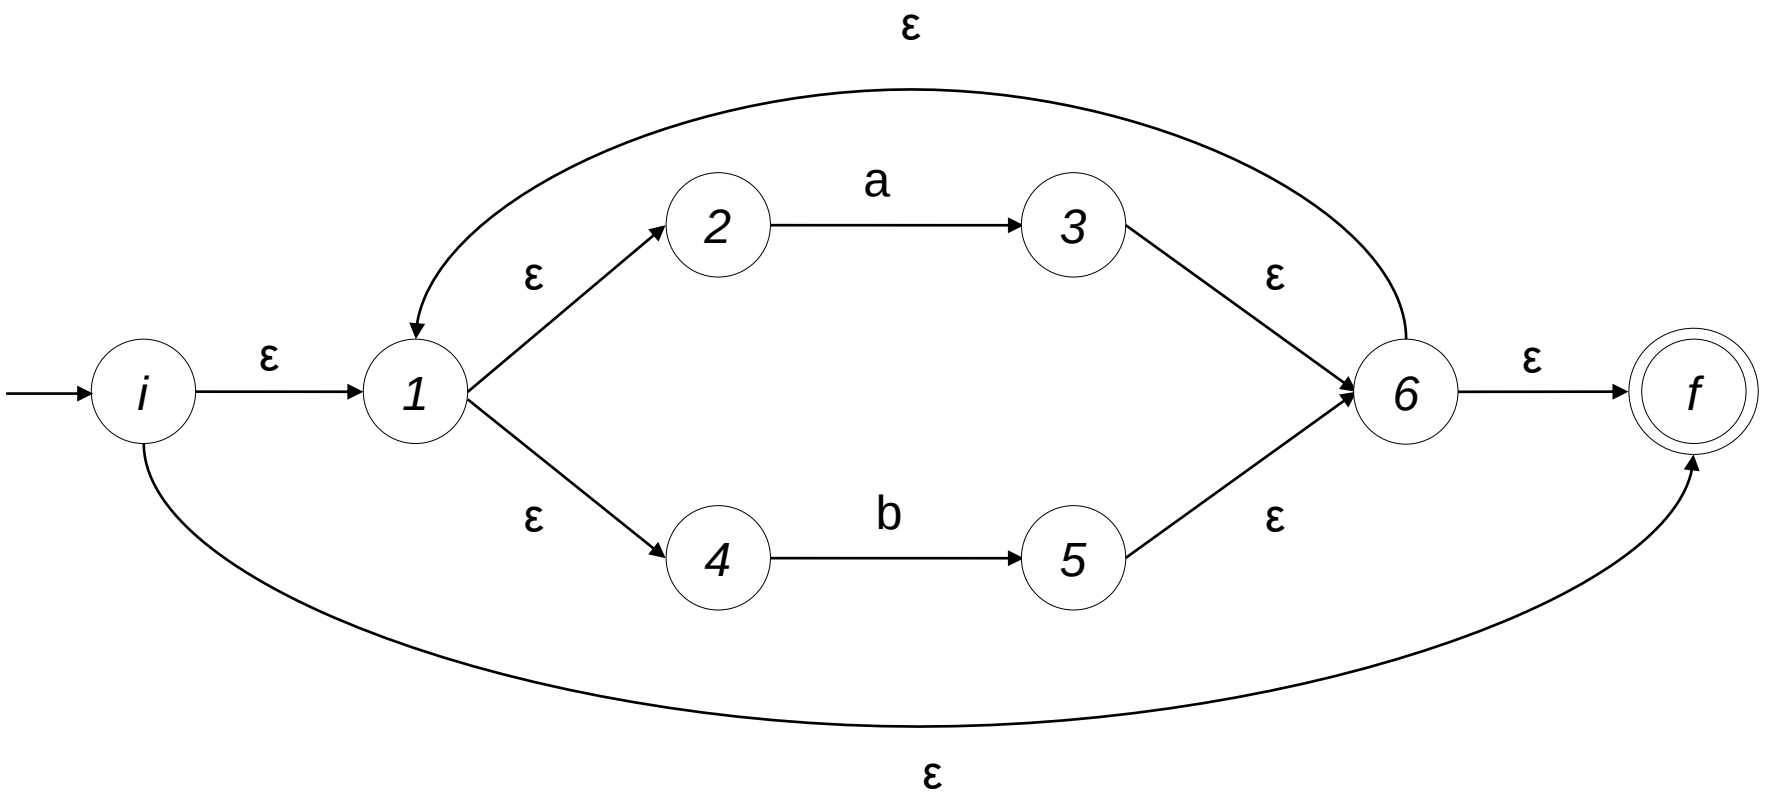

Conversão Expressões Regulares

- **Exemplo:** considere ***R = (a|b)*abb***
  - ***4 Passo:*** operações de concatenação

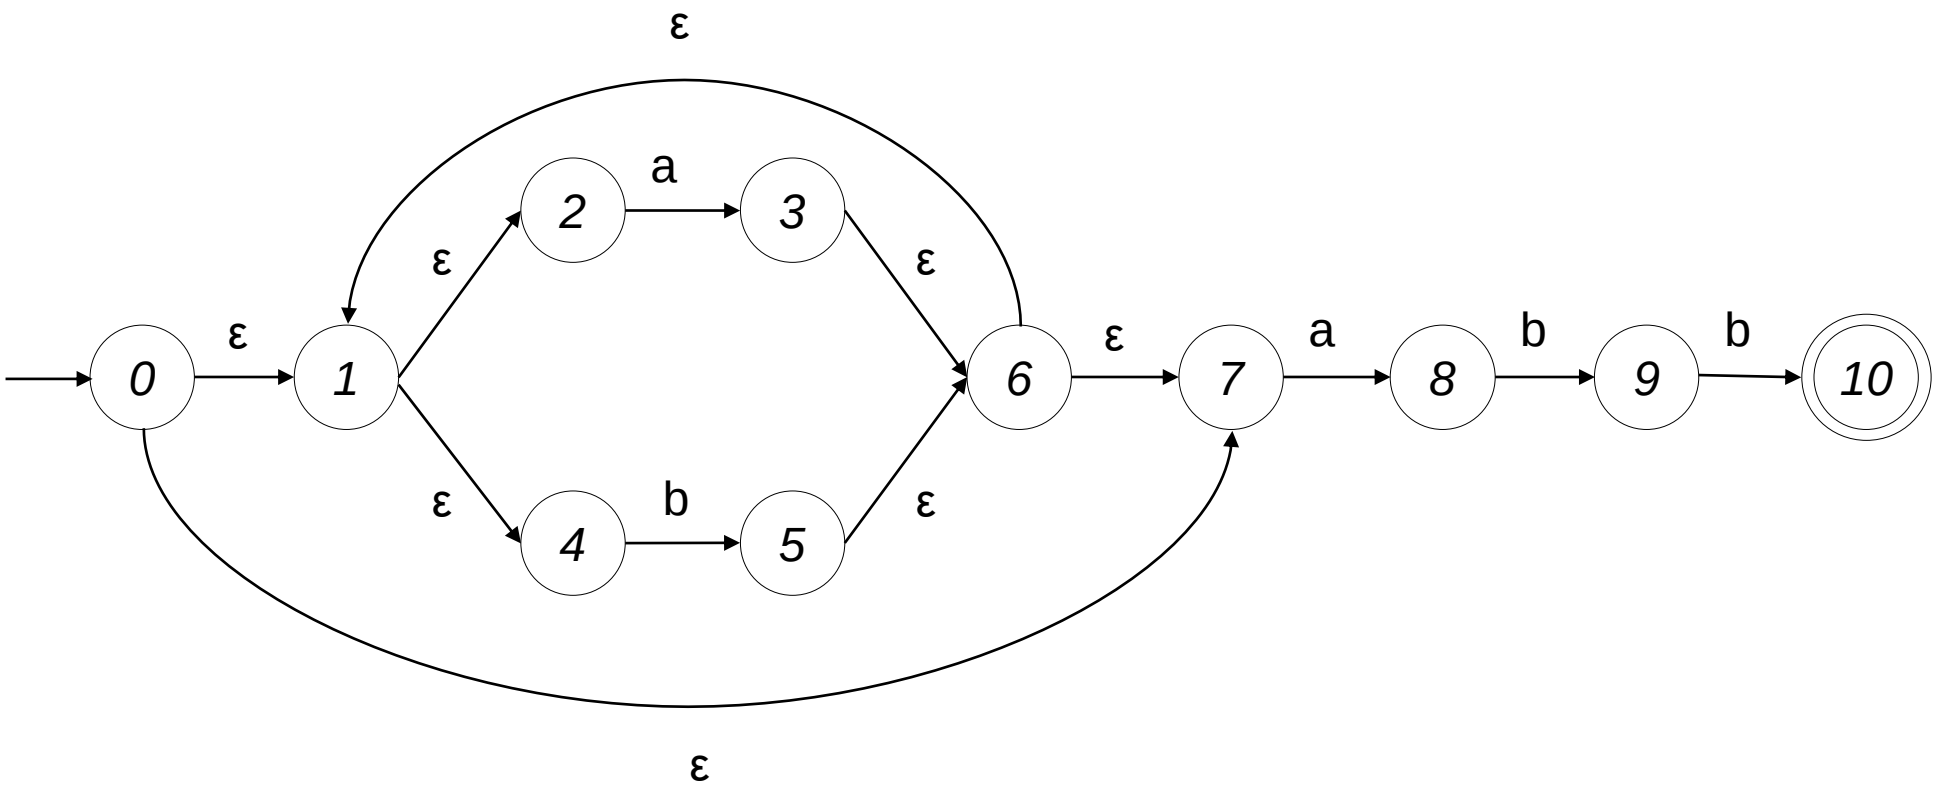

Conversão Expressões Regulares

- **Algumas propriedades do algoritmo:**
  - AFND gerado tem um estado inicial e um final
    - Estado inicial não possui transições de entrada
    - Estado final não possui transições de saída
  - AFND gerado tem no máximo o dobro de estados em relação ao número de operadores e operandos da expressão regular
    - Cada passo do algoritmo cria no máximo 2 novos estados
  - Cada estado do AFND (exceto o final) possui:
    - Uma transição de saída em um símbolo do alfabeto
    - Duas transições de saída (ambas em ε)

Conversão AFND para AFD

- Baseado na **construção de subconjuntos**:
  - **Cada estado** do AFD corresponde a um **conjunto de estados do AFND**
  - **Tabela de transição** do AFD simula **todos os movimentos do AFND** considerando os possíveis símbolos de entrada

- **Possíveis dificuldades** na conversão:
  - **Crescimento exponencial** do número de estados
    - Não costuma ocorrer na análise das linguagens reais
  - Tratar corretamente os **movimentos vazios**

- **Operações básicas** usadas no processo:
  - ***ε-closure*(*T*):** retorna o **conjunto de estados** do AFND que podem ser alcançados a partir de algum estado $s \in T$, usando **movimentos vazios**
    - ***ε-closure*(*s*)** retorna o **fecho-ε** de *s*
  - ***move*(*T, c*):** retorna o **conjunto de estados** do AFND que podem ser alcançados a partir de algum estado $s \in T$, ao ler o **símbolo *c***

Cálculo do *ε-closure(T)*

```
Inicio
    para ( cada estado t ∈ T ) faça
        push(P,t) // empilha o estado t na pilha
    fim para
    Fecho ← { }   // ε-closure
    enquanto ( Pilha não vazia ) faça
        pop(P,&t)  // desempilha o topo
        para ( cada estado s ∈ S ) faça
            se ( move(t,ε) = s e s ∉ Fecho ) então
                Fecho ← Fecho ∪ s
                push(P,s)
            fim se
        fim para
    fim enquanto
Fim
```

Implementa uma **busca direta em um grafo** a partir de um **conjunto de estados *T*** e considerando apenas os **movimentos vazios** (arestas com *ε*)

Cálculo do *ε-closure(T)*

```
Inicio
    para ( cada estado t ∈ T ) faça
        push(P,t) // empilha o estado t na pilha
    fim para
    Fecho ← { }   // ε-closure
    enquanto ( Pilha não vazia ) faça
        pop(P,&t)  // desempilha o topo
        para ( cada estado s ∈ S ) faça
            se ( move(t,ε) = s e s ∉ Fecho ) então
                Fecho ← Fecho ∪ s
                push(P,s)
            fim se
        fim para
    fim enquanto
Fim
```

Implementa uma **busca direta em um grafo** a partir de um **conjunto de estados *T*** e considerando apenas os **movimentos vazios** (arestas com *ε*)

Conversão AFND para AFD

- **Entrada:** um **AFND *N*** com estado inicial *s* e estados finais *F*
- **Saída:** um **AFD *D*** equivalente a *N* com estado inicial *S'* e estados finais *F'*

```
Inicio
    S' ← ε-closure( s ) // estado inicial de D
    S ← S'              // conj. estados de D
    M ← { }             // conj. de estados marcados
    enquanto ( ∃ T ∈ S não marcado ) faça
        M ← M ∪ T // marca T
        para ( cada símbolo c ∈ Σ ) faça
            T' ← ε-closure( move(T,c) )
            Se ( T' ∉ S ) então S ← S ∪ T'
            tabTrans[T,c] ← T' // cria transição em D
        fim para
    fim enquanto
...
```

```
...
    para ( cada conj. estado T ∈ S ) faça
        para ( cada estado s ∈ T ) faça
            se ( s ∈ F ) então
                F' ← T // estado final de D
                break
            fim se
        fim para
    fim para
Fim
```

Conversão AFND para AFD

- **Exemplo:** considere o AFND de ***R = (a|b)*abb***

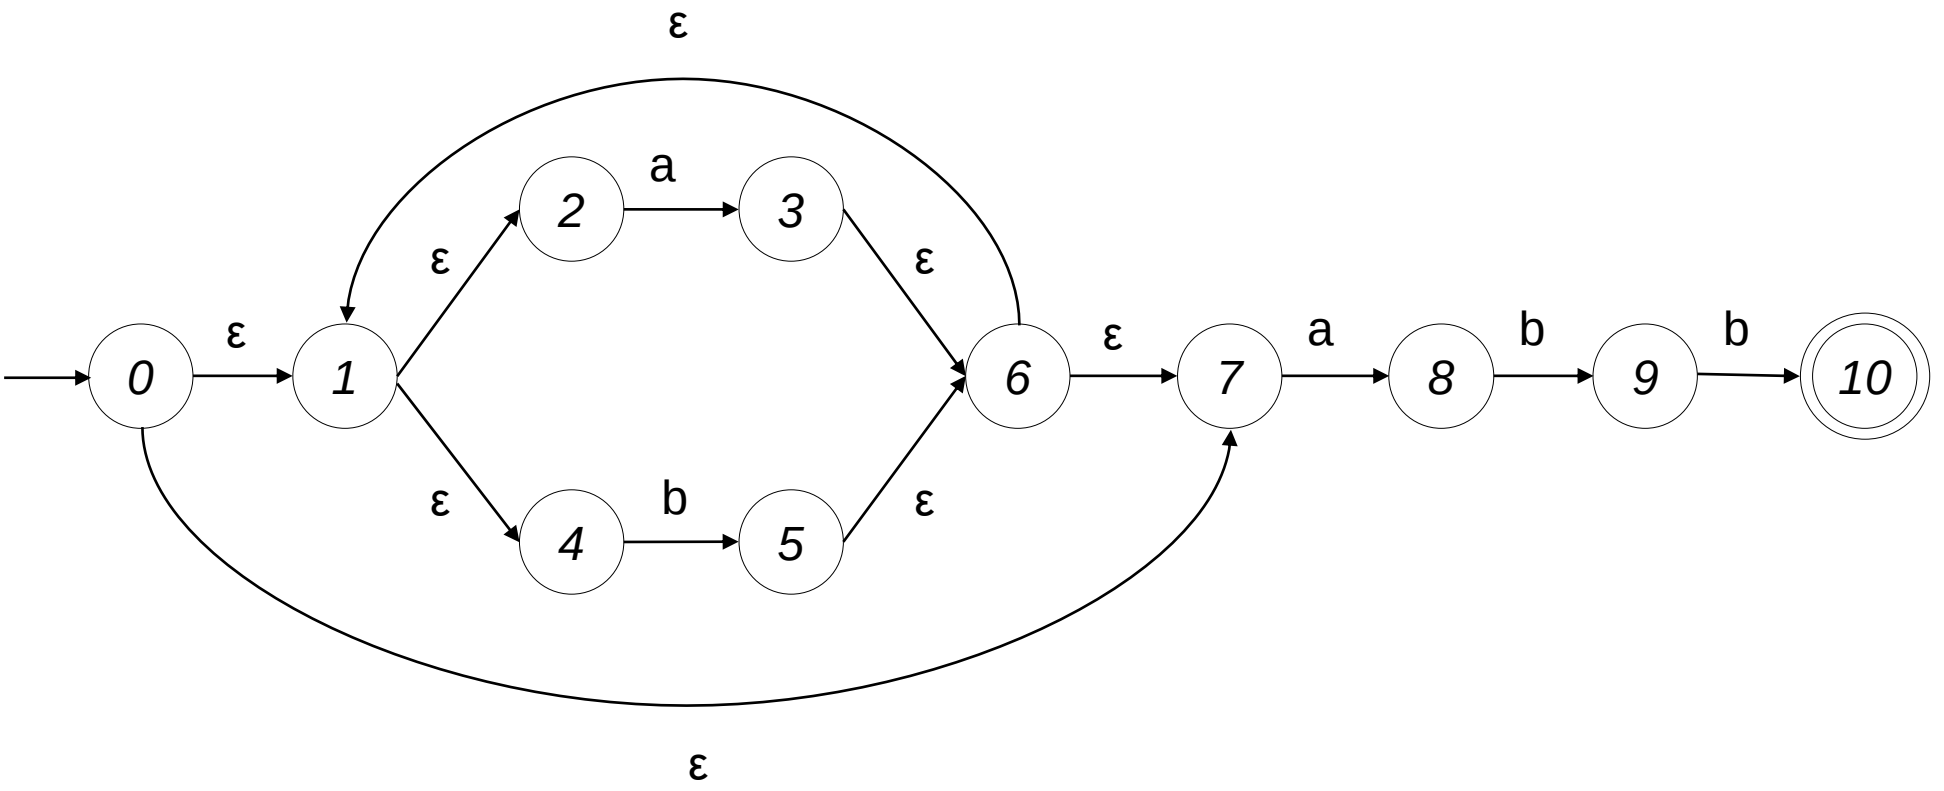

Conversão AFND para AFD

- **Exemplo:** considere o AFND de ***R = (a|b)*abb***

Estado AFND	Estado AFD	*a*	*b*
{0,1,2,4,7}	*A*	*B*	*C*
{1,2,3,4,6,7,8}	*B*	*B*	*D*
{1,2,4,5,6,7}	*C*	*B*	*C*
{1,2,4,5,6,7,9}	*D*	*B*	*E*
{1,2,4,5,6,7,10}	*E*	*B*	*C*

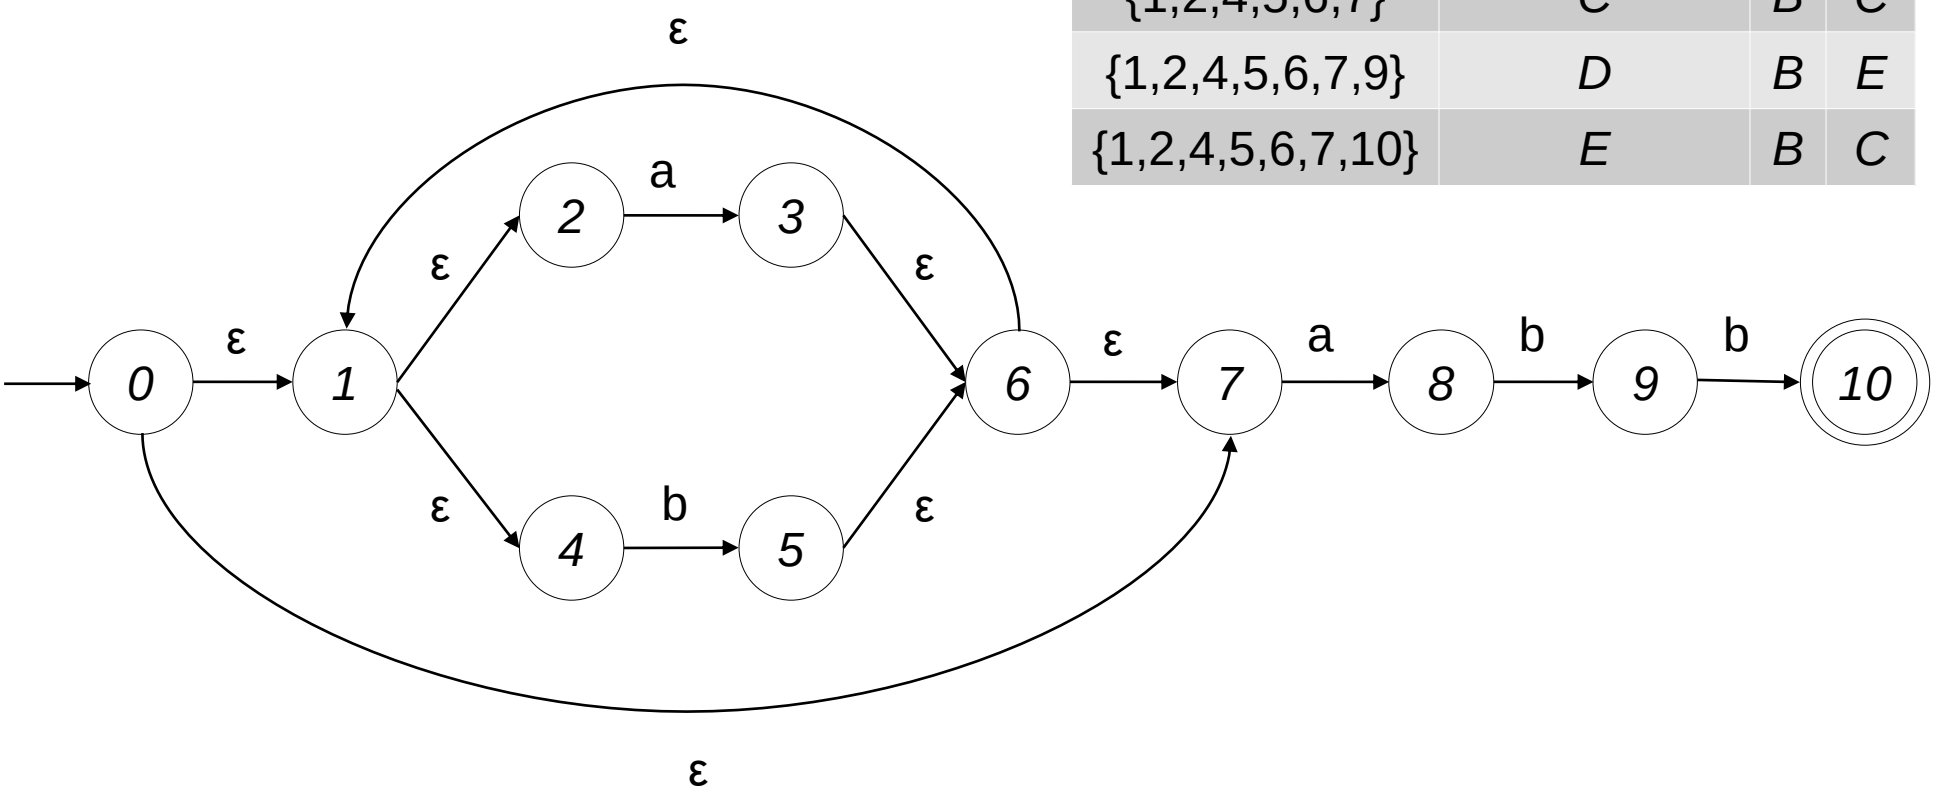

Conversão AFND para AFD

- **Exemplo:** considere o AFND de ***R = (a|b)*abb***

	Estado AFND	Estado AFD	*a*	*b*
➡	{**0**,1,2,4,7}	***A***	*B*	*C*
	{1,2,3,4,6,7,8}	*B*	*B*	*D*
	{1,2,4,5,6,7}	*C*	*B*	*C*
	{1,2,4,5,6,7,9}	*D*	*B*	*E*
*	{1,2,4,5,6,7,**10**}	***E***	*B*	*C*

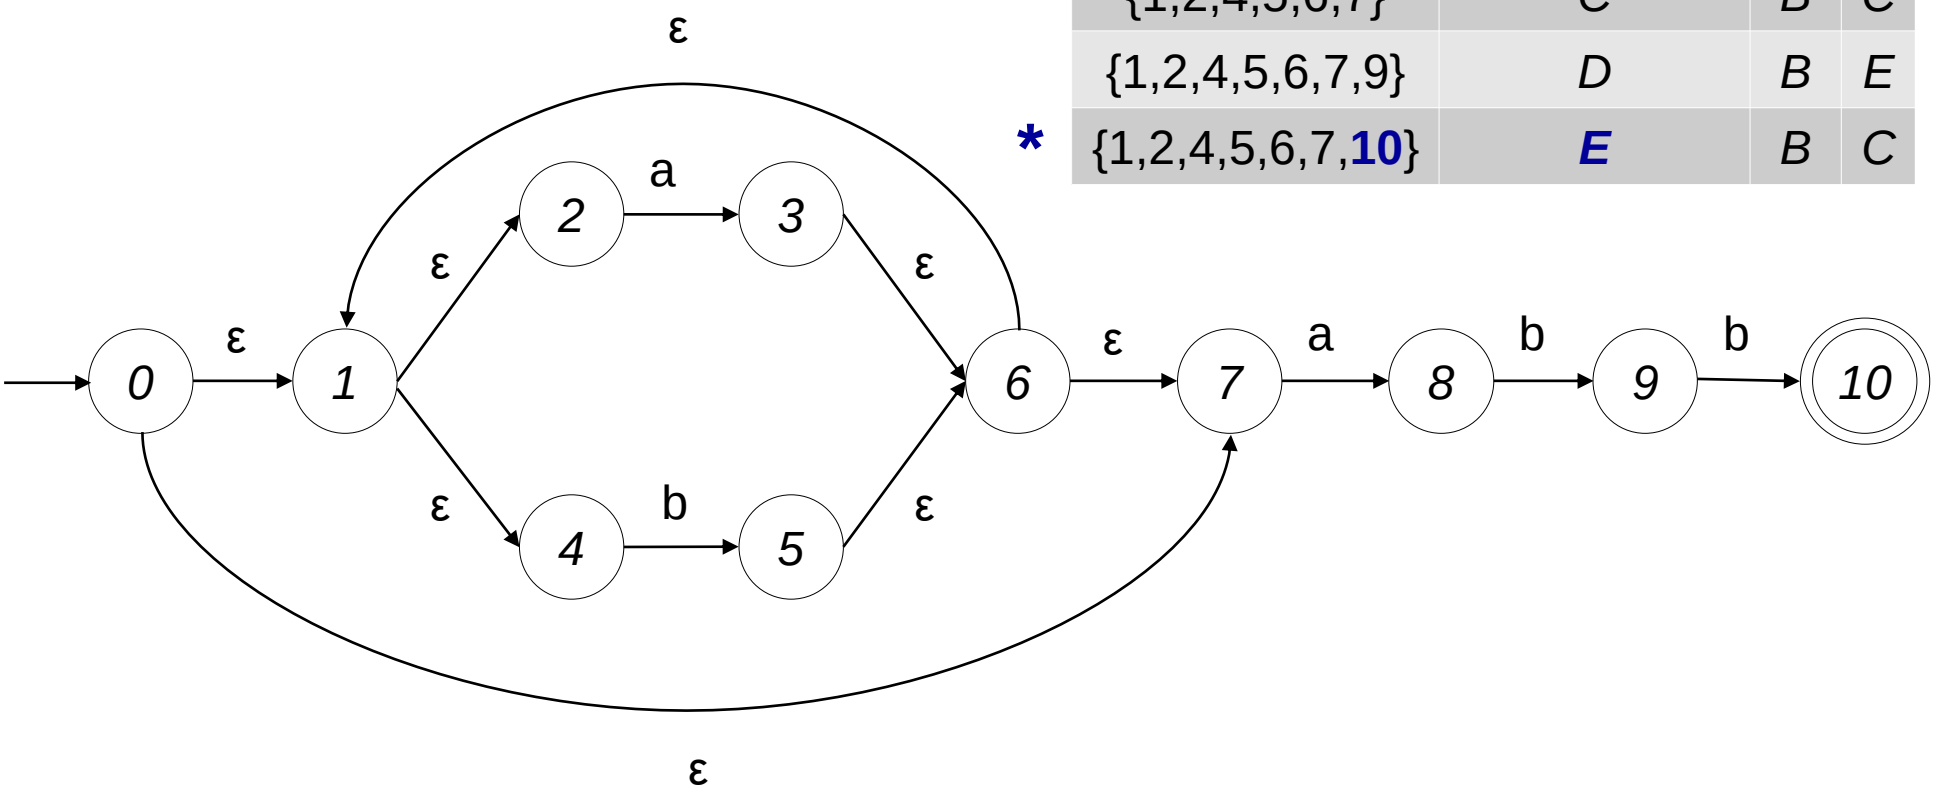

Conversão AFND para AFD

- **Exemplo:** considere o AFND de ***R = (a|b)*abb***

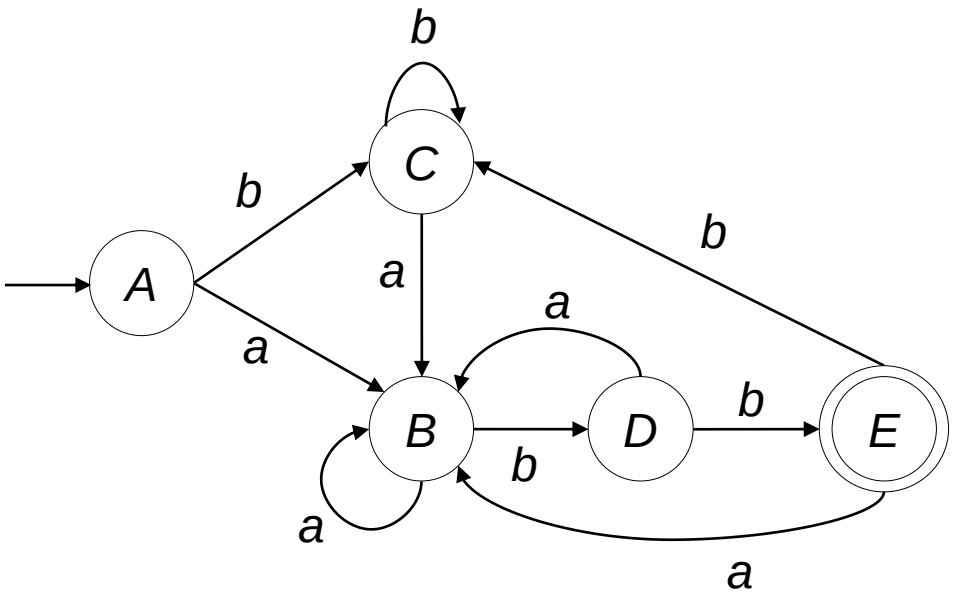

	Estado AFND	Estado AFD	*a*	*b*
➡	{**0**,1,2,4,7}	***A***	*B*	*C*
	{1,2,3,4,6,7,8}	*B*	*B*	*D*
	{1,2,4,5,6,7}	*C*	*B*	*C*
	{1,2,4,5,6,7,9}	*D*	*B*	*E*
*	{1,2,4,5,6,7,**10**}	***E***	*B*	*C*

Conversão AFND para AFD

- **Exemplo:** considere o AFND de ***R = (a|b)*abb***

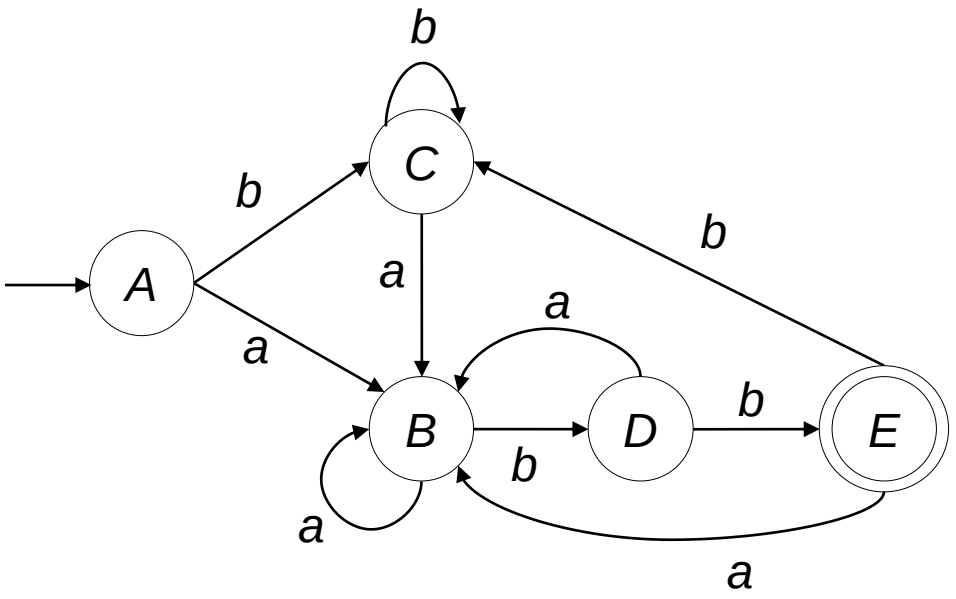

	Estado AFND	Estado AFD	*a*	*b*
➡	{**0**,1,2,4,7}	***A***	*B*	*C*
	{1,2,3,4,6,7,8}	*B*	*B*	*D*
	{1,2,4,5,6,7}	*C*	*B*	*C*
	{1,2,4,5,6,7,9}	*D*	*B*	*E*
*	{1,2,3,5,6,7,**10**}	***E***	*B*	*C*

É o AFD ótimo (menor possível)?

Conversão AFND para AFD

- **Exemplo:** considere o AFND de ***R = (a|b)*abb***

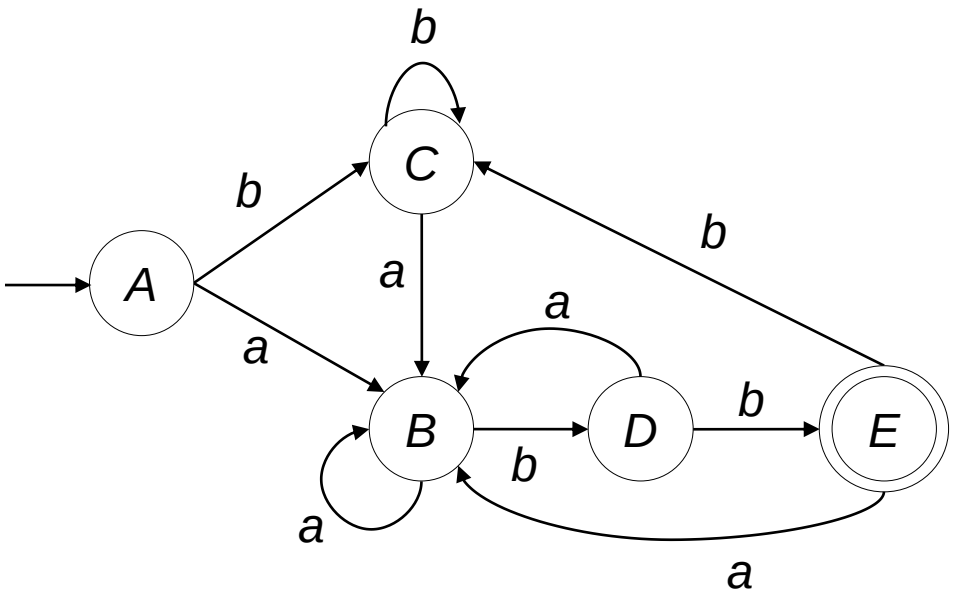

	Estado AFND	Estado AFD	*a*	*b*
➡	{**0**,1,2,4,7}	***A***	*B*	*C*
	{1,2,3,4,6,7,8}	*B*	*B*	*D*
	{1,2,4,5,6,7}	*C*	*B*	*C*
	{1,2,4,5,6,7,9}	*D*	*B*	*E*
*	{1,2,3,5,6,7,**10**}	***E***	*B*	*C*

É o AFD ótimo (menor possível)?

R: Não, pois *A* e *C* possuem as mesmas transições e, portanto, podem ser unidos

Minimização de Estados do AFD

- **Elimina estados** do AFD que possuem **as mesmas transições**

- **Algoritmo:**
  - **Separe o conjunto de estados** do AFD (*S*) em:
    - S_1**:** subconjunto com todos os **estados finais** (*F*)
    - S_2**:** subgrupo contendo os **estados não-finais** (*S* – *F*)
  - **Particione cada subconjunto** S_N de modo que 2 estados de *S* permanecerão juntos se **eles possuírem as mesmas transições**
  - **Repita o passo anterior** para os novos subgrupos até que **não seja possível novas partições**

Minimização de Estados do AFD

- **Exemplo:** considere o AFND de ***R = (a|b)*abb***

	Estado AFD	*a*	*b*
➡	*A*	*B*	*C*
	B	*B*	*D*
	C	*B*	*C*
	D	*B*	*E*
*	*E*	*B*	*C*

Estados de não aceitação:

{A,B,C,D} → {A,C}, {B}, {D}

Estados de aceitação:

{E}

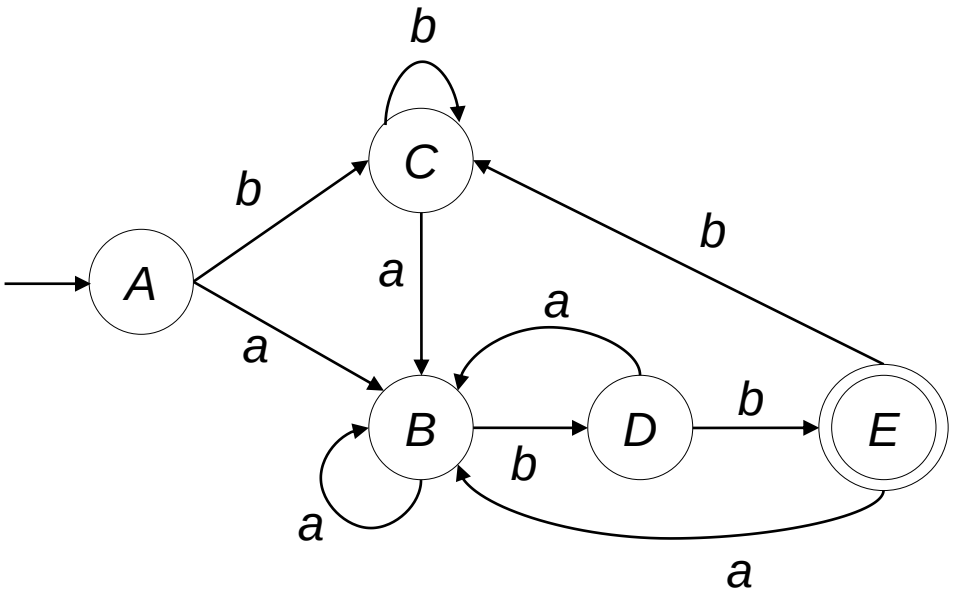

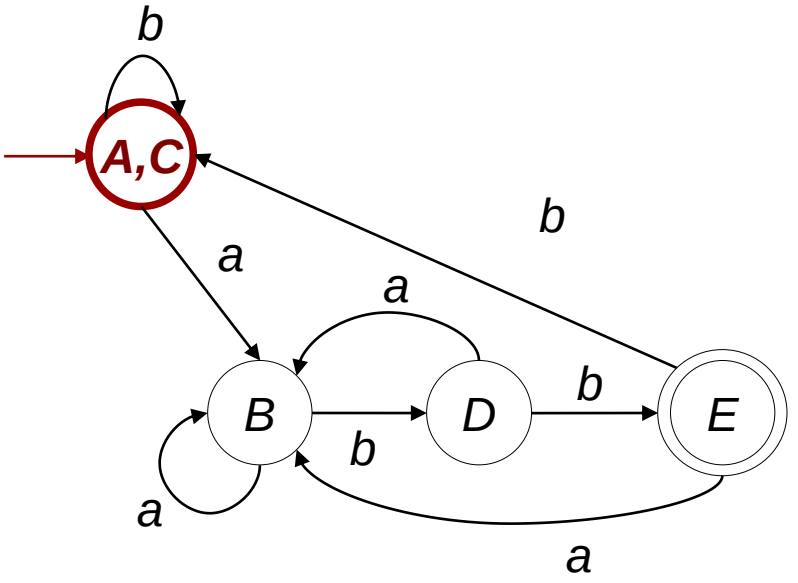

Estados Desnecessários

- AFD minimizado ainda pode conter estados cujo a remoção não altera a linguagem reconhecida
  - **Inalcançáveis** a partir do estado inicial
  - Estados "**mortos**"
  - **Ex:**

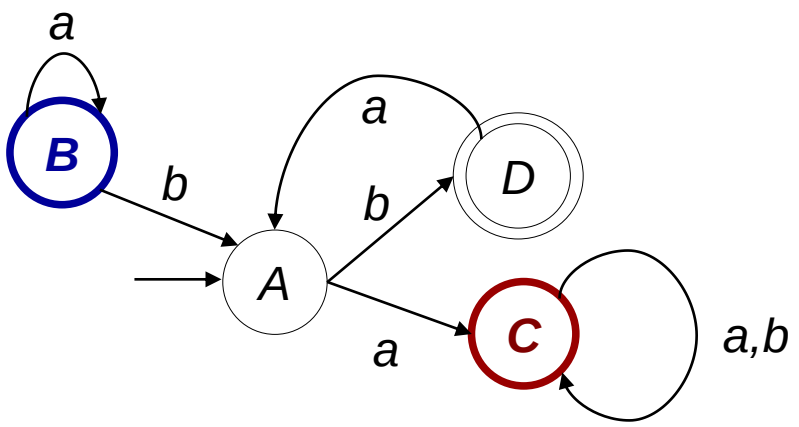

- Remoção desses estados pode melhorar a eficiência do autômato
  - **Ex:** antecipa a identificação de erros (rejeição)

Simulação de um AFD

- **Entrada:** Um **AFD *D*** e uma **cadeia de entrada *x***

- **Saída:** **1** – se *D* aceitar *x* **ou 0** – caso contrário

- **Algoritmo:**

Inicio

$s \leftarrow s_0$ *// estado inicial*

c ← prox_char()

enquanto *(c ≠ EOF) faça*

s ← move(s,c)

c ← prox_char()

fim enquanto

se *(final(s))* ***então*** *retorna 1*

senão *retorna 0*

Fim

Código baseado em tabela de transição

Simulação de um AFND

- Simulação baseada na **construção de subconjuntos** durante a execução
  - Ao invés de um estado guarda um **conjunto de possíveis estados**
  - Deve simular o **paralelismo** da busca
  - Busca é encerrada quando **não existe transição** para a entrada
    - Conjunto de estados é vazio
    - Garante a obtenção do maior prefixo de entrada

- Passos do algoritmo:
  - Guardar o **conjunto de estados correntes** S_c
  - Obter os **próximos estados** S_p a partir do caractere de entrada *c*
    - **Realizar a transição** sobre o conjunto S_c (***move(*** S_c ***, c)***)
    - **Aplicar o fecho-ε** sobre o resultado da transição

Simulação de um AFND

- **Entrada:** Um **AFND *N*** e uma **cadeia de entrada *x***

- **Saída:** **1** – se *N* aceitar *x* **ou 0** – caso contrário

- **Algoritmo:**

Inicio

$S_c \leftarrow \varepsilon\text{-closure}(s_0)$

c ← prox_char()

enquanto *(c ≠ EOF)* ***faça***

$S_p \leftarrow \varepsilon\text{-closure}(move(S_c , c))$

c ← prox_char()

$S_c \leftarrow S_p$

fim enquanto

se *(final(S_c))* ***então*** *retorna 1*

senão *retorna 0*

Fim

Simulação de um AFND

- Forma de implementação pode melhorar eficiência
  - **Ex:** intercalar pilhas é mais eficiente que copiá-las em cada iteração

- **Estruturas de dados:**
  - **2 pilhas:** armazena um conjunto de estados
    - Conjunto de estados **atual** e o **próximo**
  - **Vetor de visitados:** indica os estados que já estão como próximo
    - Vetor pode ser binário ou booliano
    - Replica dados, mas **facilita a consulta**
  - **Matriz de listas:** contém a tabela de transição do AFND
    - Cada elemento (**lista encadeada**) representa o conjunto de estados resultante da transição

- **Operações auxiliares:**
  - Inicializar o vetor binário (**todos elementos igual a ZERO**)
  - Computar o **fecho-ε** sobre um estado (***ε-closure(T,s)***)
  - Computar a **transição para um conjunto** de estados

Simulação de um AFND

- **Intercalação das pilhas:**

Inicio

$S_1 \leftarrow \varepsilon\text{-closure}(s_0)$

$Flag \leftarrow 0$

$c \leftarrow prox\_char()$

enquanto $(c \neq EOF)$ ***faça***

fim enquanto

se $((Flag = 0$ ***e*** $final(S_1)))$ ***ou***

$(Flag = 1$ ***e*** $final(S_2)))$ ***então***

retorna 1

senão *retorna 0*

Fim

se $(Flag = 0)$ ***então***

$S_2 \leftarrow \varepsilon\text{-closure}(move(S_1 , c))$

$Flag \leftarrow 1$

senão

$S_1 \leftarrow \varepsilon\text{-closure}(move(S_2 , c))$

$Flag \leftarrow 0$

fim se

$c \leftarrow prox\_char()$

Simulação de um AFND

Cálculo do Fecho-ε

```
Função ε-closure ( End. Pilha P, estado s)
    push(P, s)
    visitado[s] ← 1
    para ( t em move(s, ε) ) faça
        se ( visitado[t] = 0 ) então
            ε-closure (P, t)
        fim se
    fim para
Fim função
```

Cálculo da Transição
(*ε-closure(* S_p **, move(S_c **, c))**)**

```
enquanto (Sc não vazia) faça
    pop(Sc , &s) // Desempilha atual
    para (t em move(s, c)) faça
        se ( visitado[t] = 0 ) então
            ε-closure (Sp , t)
        fim se
    fim para
fim enquanto
```

Função ***ε-closure*** modificada para passar **endereço da pilha como parâmetro**

Simulação de um AFND

- **Exemplo:** padrões a, abb, a^*b^+

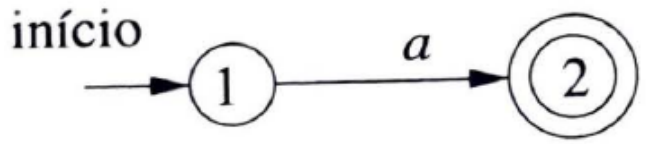

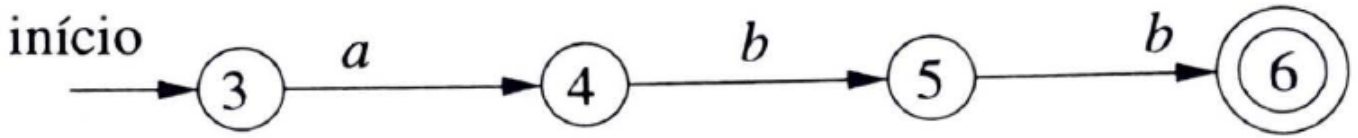

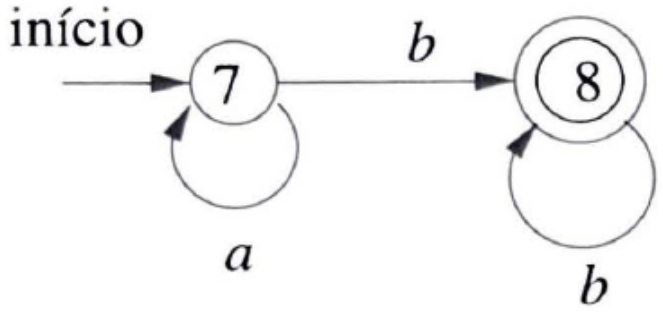

Autômatos dos padrões

Simulação de um AFND

- **Exemplo:** padrões a, abb, a*b^{+}

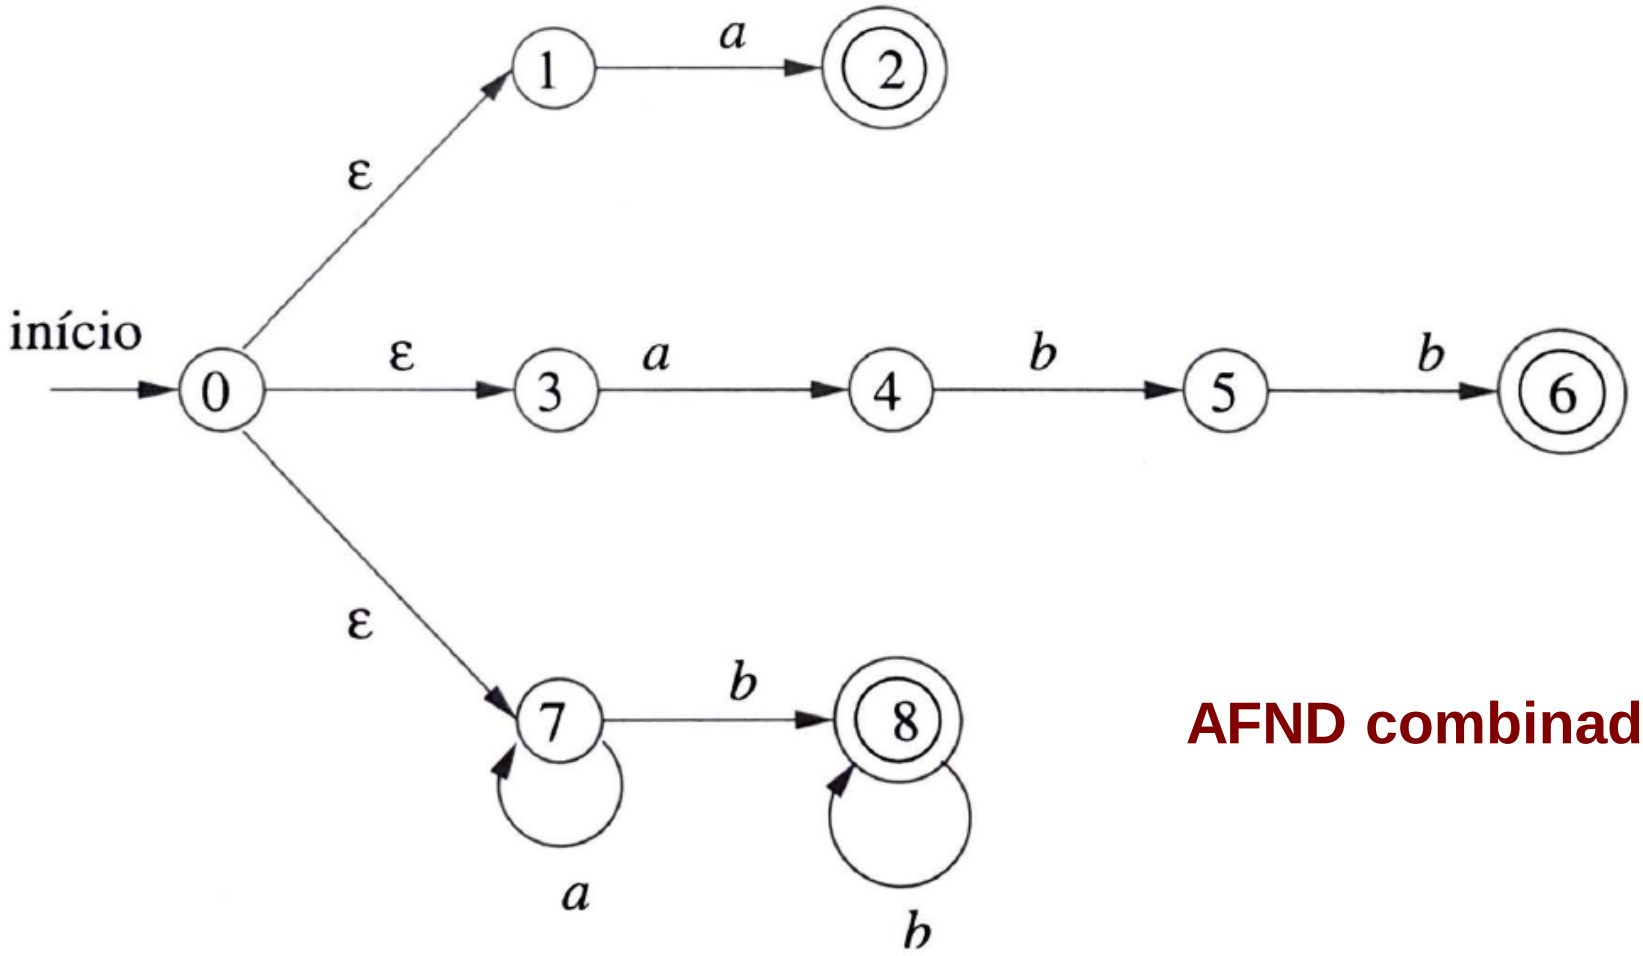

AFND combinado

Simulação de um AFND

- **Exemplo:** padrões a, abb, a*b$^+$

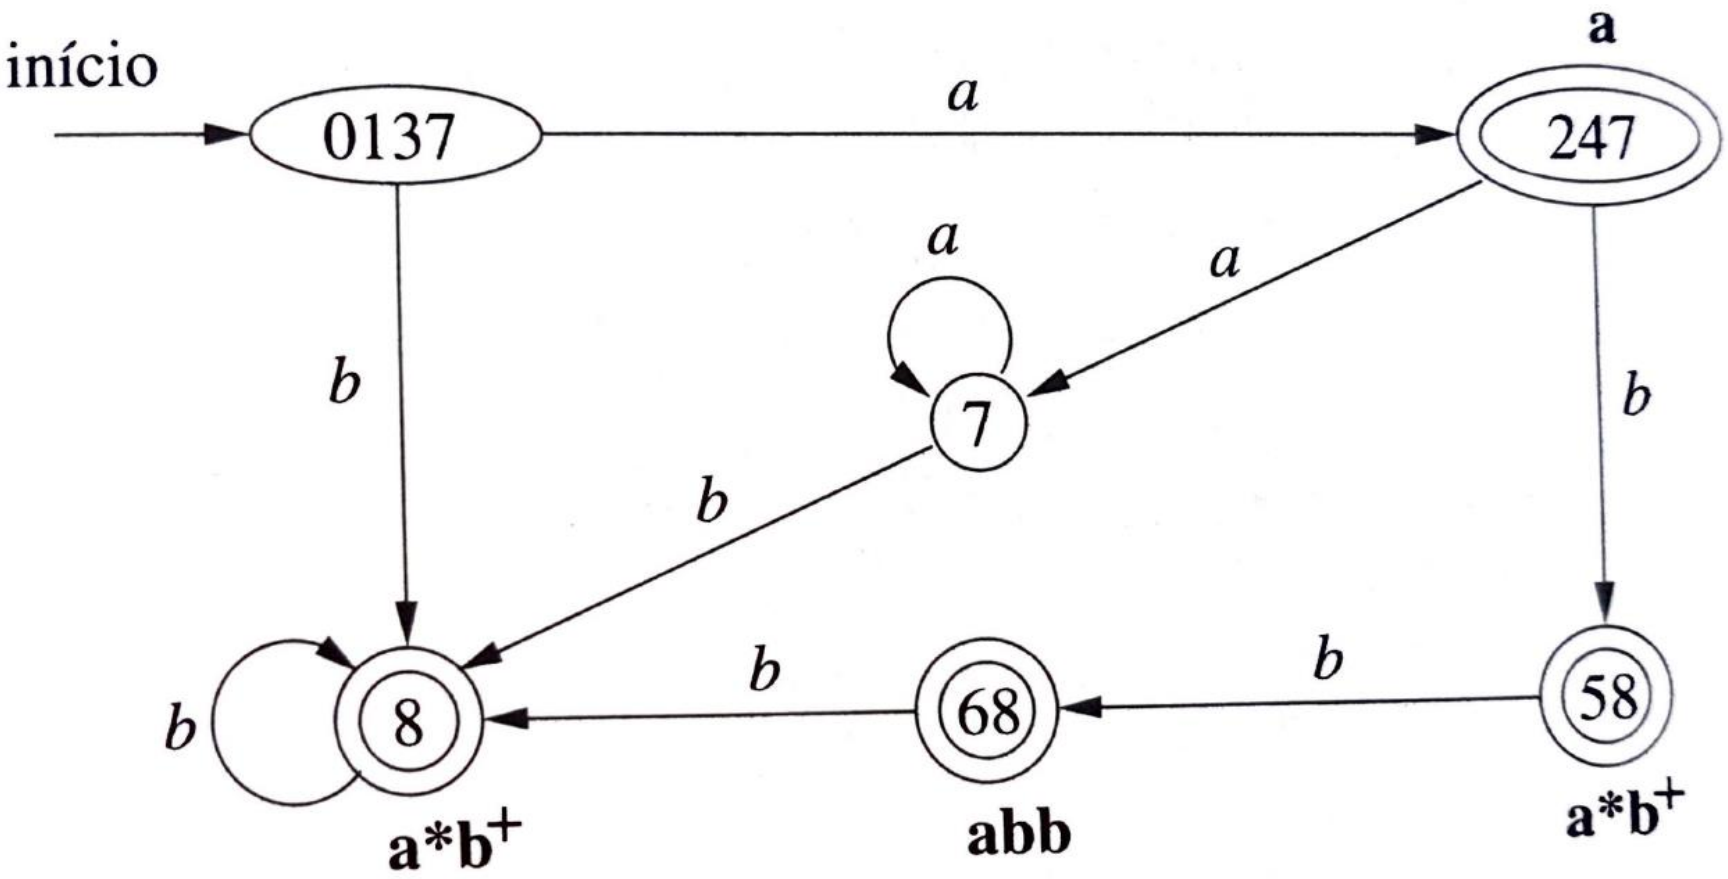

AFD resultante

Simulação de um AFND

- **Exemplo:** padrões a, abb, a^*b^+

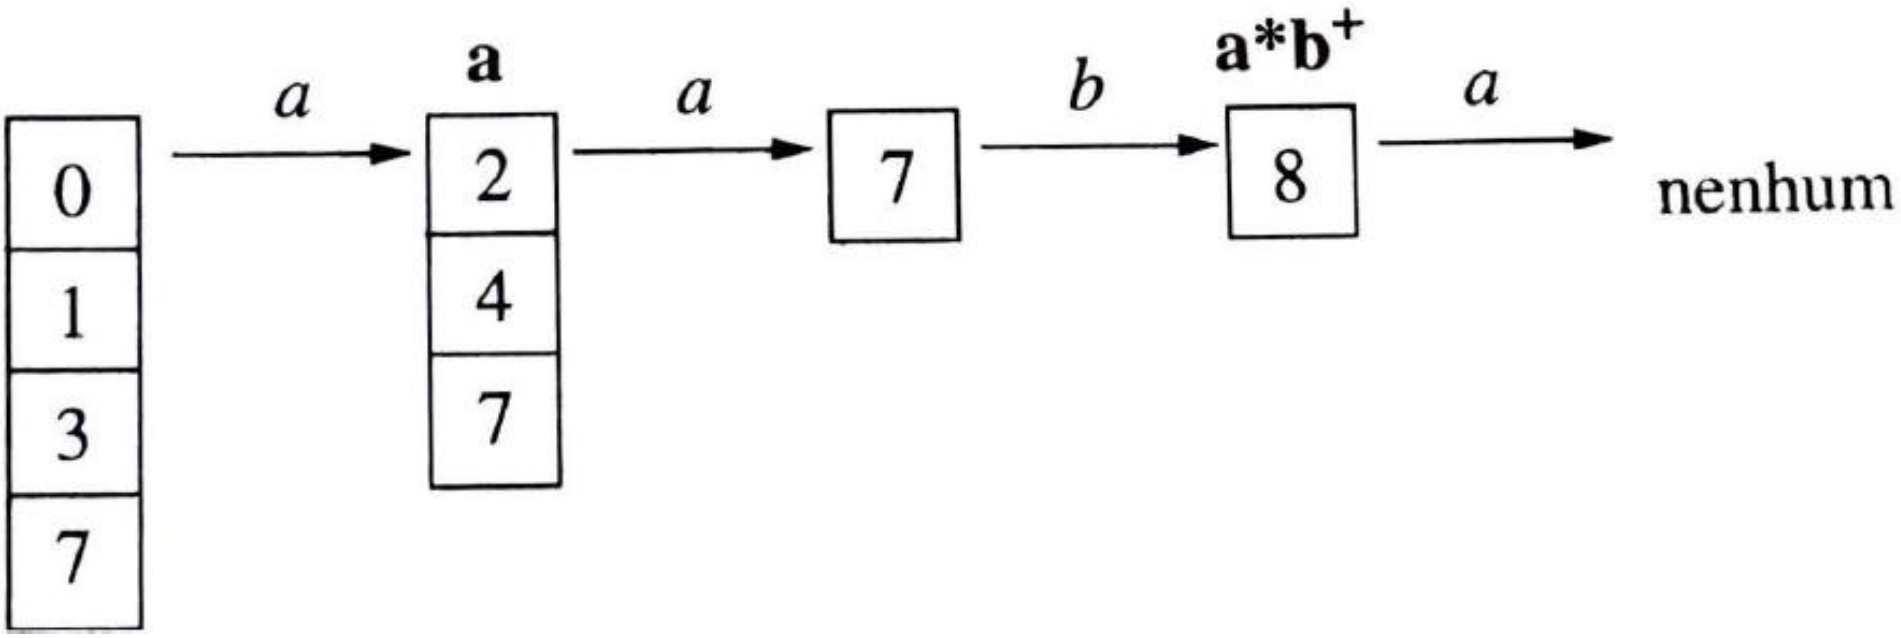

Processamento da entrada ***aaba***

Referências Bibliográficas

- Aho, A.V.; Lam, M.S.; Sethi, R.; Ullman, J.D. Compiladores: Princípios, técnicas e ferramentas, 2 edição, Pearson, 2008
- Alexandre, E.S.M. Livro de Introdução a Compiladores, UFPB, 2014
- Aluisio, S. slides da disciplina “Teoria da Computação e Compiladores”, ICMC/USP, 2011
- Dubach, C. slides da disciplina “*Compiling Techniques*”, University of Edinburgh, 2018
- Freitas, R. L. notas de aula - Compiladores, PUC Campinas, 2000
- GeeksforGeeks, Flex (*Fast Lexical Analyser Generator*), https://www.geeksforgeeks.org/flex-fast-lexical-analyzer-generator/